



UNIVERSIDADE DE SÃO PAULO
ESCOLA DE ARTES, CIÊNCIAS E HUMANIDADES

PATRÍCIA RUFINO OLIVEIRA

**Técnicas de Inteligência Artificial para Suporte ao Processo de Descoberta
de Medicamentos**

São Paulo

2021

PATRÍCIA RUFINO OLIVEIRA

**Técnicas de Inteligência Artificial para Suporte ao Processo de Descoberta
de Medicamentos**

Versão original

Texto sistematizado apresentado à Escola de Artes, Ciências e Humanidades da Universidade de São Paulo como parte dos requisitos para obtenção do título de Livre Docente.

Área de concentração: Computação

São Paulo

2021

Agradecimentos

A Profa. Dra. Káthia Maria Honório pela parceria em projetos e publicações e pela oportunidade da troca de conhecimento e experiências que proporcionaram o desenvolvimento dessa pesquisa de caráter interdisciplinar.

Aos colegas do curso de Bacharelado em Sistemas de Informação e do Programa de Pós-Graduação da EACH-USP, pelo compartilhamento de ideias e convívio harmonioso.

Aos alunos que orientei ao longo desses anos e aos bolsistas dos projetos envolvidos na investigação aqui apresentada.

Ao CNPq, Pró-Reitoria de Pesquisa da USP, FAPESP e IBM pelo auxílio financeiro.

Resumo

O processo de desenvolvimento de um novo medicamento envolve a identificação dos alvos terapêuticos para uma determinada doença, a descoberta de compostos bioativos e a realização paralela de ensaios biológicos para validar a eficiência e os efeitos colaterais da droga. Esse processo é longo e custoso e pode levar mais de 10 anos para ser concluído. Assim, a integração de técnicas de Inteligência Artificial (IA) a esse cenário pode funcionar como um “atalho”, reduzindo o número de compostos químicos a serem testados em laboratório. Esta monografia discute o desenvolvimento e a utilização de métodos de IA para apoiar pesquisas em descoberta de medicamentos. Em especial, considera-se aqui técnicas de aprendizado de máquina para a identificação de compostos candidatos a medicamento e a construção de uma ontologia para esses estudos. A ideia é que essa ontologia possa ser aplicada para orientar a seleção de conjuntos de dados em experimentos de transferência de aprendizado e para explorar as relações entre drogas e alvos terapêuticos, a fim de entender como as modificações nas características estruturais dos compostos químicos induzem sua atividade biológica.

Palavras-chaves: Descoberta de medicamentos; Ontologias; Aprendizado de máquina.

Abstract

The process of developing a new drug involves identifying therapeutic targets for a given disease, discovering bioactive compounds, and carrying out parallel biological assays to validate the drug's efficiency and effects. This process is long and costly and can take over 10 years to complete. Thus, integrating Artificial Intelligence (AI) techniques to this scenario can work as a "shortcut", reducing the number of chemical compounds to be tested in laboratory. This monograph discusses the development and use of AI methods to support research in drug discovery. In particular, the focus is on machine learning techniques for identifying drug candidates and on the construction of an ontology for these studies. The intent is that this ontology can be applied to guide the selection of datasets in transfer learning experiments and to explore the relationships between drugs and therapeutic targets, aiming to comprehend how structural changes in chemical compounds impact their activity biological.

Keywords: Drug discovery, Ontologies, Machine learning.

Lista de figuras

Figura 1 – O processo de desenvolvimento de um novo medicamento e suas principais atividades e tempo médio de duração. Figura adaptada de (RéDA; KAUFMANN; DELAHAYE-DURIEZ, 2020).	12
Figura 2 – Ilustração de vetores suporte para o problema de regressão com as variáveis de folga ξ e ξ^* nos dois lados do hiperplano. Figura adaptada de (LIMA, 2004).	16
Figura 3 – Fragmento da Ontologia OntoQSAR.	19
Figura 4 – Esquema geral para estudos QSAR. Os conjuntos de dados para essas análises são formados por descritores químicos que representam moléculas para as quais foram observados valores de atividade em ensaios biológicos. Esses estudos podem ser aplicados para tarefas de agrupamento, regressão ou classificação (composto ativo; inativo), caso as observações tenham sido previamente rotuladas por especialistas no domínio.	23
Figura 5 – Metodologia baseada em técnicas de IA para o suporte à descoberta de medicamentos.	24
Figura 6 – Ilustração do conhecimento transferido a partir da tarefa de origem, que contém uma grande quantidade de dados de treinamento (verde) para uma tarefa de destino, que contém poucos dados de treinamento (azul). Os tubos ϵ -sensível ao redor da funções de regressão $\mathbf{w}_s^T \mathbf{x}$ e $\mathbf{w}_t^T \mathbf{x}$ são descritos pelas linhas tracejadas. Figura adaptada de (ROSENBAUM <i>et al.</i> , 2013).	33
Figura 7 – Metodologia utilizada para desenvolver a ontologia OntoQSAR. Adaptado de (FALBO, 2014).	38
Figura 8 – Visão parcial da OntoQSAR com oito classes e 29 subclasses.	41
Figura 9 – Um fragmento da ontologia OntoQSAR produzido pela ferramenta Protégé.	42
Figura 10 – Exemplo de um vetor de similaridade entre um conjunto de Dados D_1 e os conceitos de uma ontologia.	45

Figura 11 – Visão geral do sistema proposto para avaliação e interpretação de resultados QSAR.	47
--	----

Lista de tabelas

Tabela 1 – Projetos de pesquisa financiados.	13
Tabela 2 – Questões de competência para a ontologia OntoQSAR.	39
Tabela 3 – Algumas restrições de cardinalidade da ontologia OntoQSAR.	41

Sumário

1	Introdução	10
1.1	<i>Visão Geral</i>	10
1.2	<i>Trabalhos considerados</i>	12
1.3	<i>Projetos de pesquisa financiados</i>	13
1.4	<i>Organização do trabalho</i>	13
2	Conceitos fundamentais	15
2.1	<i>Regressão por Vetores Suporte (SVR)</i>	15
2.2	<i>Ontologias</i>	18
3	Metodologia baseada em IA para o suporte à descoberta de medicamentos	20
3.1	<i>O processo de descoberta de medicamentos</i>	20
3.1.1	<i>Abordagens para identificação e validação do alvo biológico</i>	20
3.1.2	<i>Descritores químicos</i>	21
3.1.3	<i>Estudos de relações quantitativas estrutura-atividade</i>	22
3.2	<i>Metodologia proposta</i>	24
4	Técnicas de aprendizado de máquina para suporte à descoberta de medicamentos	25
4.1	<i>Revisões de trabalhos relacionados</i>	26
4.2	<i>Modelos de consenso</i>	30
4.2.1	<i>Modelos de consenso para descoberta de medicamentos para dores neuropáticas</i>	30
4.2.2	<i>Modelos de consenso para descoberta de medicamentos contra o câncer</i>	31
4.3	<i>Transferência de aprendizado para regressão baseada em vetores suporte</i>	32
4.4	<i>Técnicas de aprendizado profundo</i>	35
5	OntoQSAR - Uma ontologia para apoio a descoberta de medicamentos	36
5.1	<i>Motivação para o desenvolvimento da OntoQSAR</i>	36

5.1.1	Falta de metadados para relacionar conceitos em estudos QSAR . .	36
5.1.2	Falta de interpretabilidade em algumas aplicações de AM	37
5.2	<i>Desenvolvimento da ontologia</i>	37
5.2.1	Identificação dos propósitos da ontologia e levantamento de requisitos	38
5.2.2	Coleta e formalização da ontologia	39
5.2.3	Projeto da ontologia	40
6	Trabalhos em andamento e perspectivas	44
6.1	<i>Busca semântica por conjuntos de dados de origem em experimentos</i> <i>de transfência de aprendizado</i>	44
6.2	<i>Desenvolvimento de um sistema para avaliação e interpretação de</i> <i>resultados QSAR</i>	46
6.3	<i>Perspectivas futuras</i>	48
7	Conclusões	49
	REFERÊNCIAS	50

1 Introdução

O custo médio necessário para o desenvolvimento de um novo medicamento para aprovação no mercado é estimado em US\$ 2,6 bilhões e leva, em média, pelo menos 10 anos. Esses recursos envolvem não apenas o desenvolvimento de medicamentos bem sucedidos, mas também os esforços para os candidatos a medicamentos que falharam nos testes clínicos. Recentemente, a probabilidade de um medicamento submetido a testes clínicos conseguir entrar no mercado foi estimada em menos de 12% (DIMASIA; GRABOWSKIB; HANSEN, 2016). Em especial, a descoberta e o desenvolvimento de medicamentos para terapias oncológicas é um processo ainda mais complexo, caro e demorado. Ao final de testes em humanos em tratamento oncológico, apenas cerca de 5% de novas substâncias são aprovadas (CARRARA *et al.*, 2017).

Nesse contexto, técnicas computacionais são ferramentas poderosas que podem reduzir o número de compostos químicos a ser analisados em ensaios experimentais, funcionando, portanto como um “atalho” para a descoberta um novo medicamento. Em especial, métodos de aprendizado de máquina (AM) têm o potencial de acelerar pesquisas na área farmacêutica por meio da extração automática de conhecimento a partir de uma vasta quantidade de dados.

1.1 Visão Geral

De forma simplificada, as pesquisas na área de descoberta de medicamentos buscam identificar pequenas moléculas com potencial para modular funções de proteínas que atuam como alvos terapêuticos no organismo, combatendo uma determinada doença. Assim, a eficácia de um medicamento está associada a sua capacidade para tratar a causa ou os sintomas de uma doença, o que acontece por meio da interação do medicamento com um alvo biológico no corpo (por exemplo, uma proteína), ou com um organismo patogênico, como um vírus ou uma bactéria.

Uma vez que a maioria dos medicamentos age inibindo a ação do alvo, assume-se, neste documento, que a eficácia de um medicamento é medida pela sua capacidade de inibir a atividade biológica do alvo. Além disso, seguindo a convenção utilizada em (YOUNG, 2009), aqui, os termos “molécula”, “composto químico” e “droga” serão aplicados de modo


intercambiável para referir-se aos compostos testados ao longo de todo o processo de descoberta de medicamentos.

O processo de desenvolvimento de um novo medicamento para uma determinada doença é dividido em três estágios principais, a saber:

1. **Descoberta de compostos candidatos a medicamento:** essa etapa envolve a identificação de alvos terapêuticos no organismo, assim como a identificação de compostos químicos capazes de interagir com estes alvos. Nesse estágio, pesquisas podem ser conduzidas para entender em quais processos ou vias biológicas o medicamento precisa intervir. Um outro experimento fundamental nessa etapa consiste na triagem de compostos testados em ensaios biológicos, de modo a verificar a sua habilidade em afetar o alvo em questão. Uma vez que esse processo de triagem dificilmente detecta um candidato “perfeito”, compostos promissores geralmente passam por um processo de otimização, que testa modificações em suas estruturas, com o objetivo de melhorar a sua atividade.
2. **Estudos pré-clínicos:** Os riscos potenciais e a eficácia do medicamento são avaliados nesse estágio. Por exemplo, estudos *in vitro* e *in vivo* são empregados, com o objetivo de avaliar propriedades dos compostos candidatos, como absorção, distribuição, metabolismo, excreção e toxicidade (conhecidas como propriedades ADME-T).
3. **Estudos clínicos:** Este último estágio envolve três fases: estudo da toxicidade da dose, efeitos colaterais de curta duração e relações cinéticas (Fase I); determinação da eficácia da droga (Fase II); e comparação da molécula com placebo ou determinado padrão de tratamento (Fase III).

A Figura 5 apresenta as principais etapas a serem cumpridas durante o desenvolvimento de um novo medicamento até a submissão deste às agências reguladoras competentes. Cabe ressaltar que, mesmo após o lançamento do medicamento no mercado, são necessárias pesquisas para monitorar os efeitos colaterais de longa duração da droga e para avaliar a utilização desta em outras terapias, procedimento que é conhecido como “reposicionamento de drogas” (JIN; WONG, 2014).

Figura 1 – O processo de desenvolvimento de um novo medicamento e suas principais atividades e tempo médio de duração. Figura adaptada de (RêDA; KAUFMANN; DELAHAYE-DURIEZ, 2020).



O foco principal desta monografia está na etapa inicial do processo de desenvolvimento de um novo medicamento. Em especial, a maioria das pesquisas e contribuições apresentadas e discutidas neste documento estão associadas à proposta de técnicas de Inteligência Artificial (IA) e suas aplicações para identificação de compostos biotivos, candidatos a medicamentos.

O objetivo desta monografia consiste em sistematizar a produção científica da autora, no que se refere ao desenvolvovimento e aplicação de técnicas de Inteligência Artificial para o suporte à descoberta de novos medicamentos. Para isso, será descrito como as suas publicações estão relacionadas; quais foram as principais contribuições e desafios; e quais são os seus trabalhos em andamento e perspectivas futuras.

1.2 Trabalhos considerados

Inicialmente, vale ressaltar que o trabalho de pesquisa aqui relatado não foi uma obra solitária, uma vez que a autora contou com a colaboração de diversos pesquisadores, dentre

estes: Káthia Maria Honório (EACH-USP), Vinícius Gonçalves Maltarollo (UFMG) e Clodoaldo Aparecido Moraes Lima (EACH-USP) e José Jesús Pérez Alcázar (EACH-USP).

As atividades desenvolvidas ao longo dessa investigação incluem projetos de pesquisa coordenados pela autora ou com a sua colaboração; publicações em periódicos ou eventos científicos; e orientações.

Como a produção científica aqui relatada encontra-se publicada, a descrição desses trabalhos será realizada de forma sucinta, com mais destaque para as contribuições científicas e desafios, e menos ênfase nos aspectos técnicos e em formulações matemáticas. Entretanto, sempre que desejado, maiores detalhes podem ser obtidos por meio de consulta às referências citadas ao longo do documento.

1.3 Projetos de pesquisa financiados

Os trabalhos compilados nesta monografia foram gerados, em grande parte, no âmbito de três projetos de pesquisa coordenados pela autora ou com a sua colaboração. Tais projetos estão relacionados na tabela 1, juntamente com a indicação das seções em que são mencionados.

Período	Descrição	Seções
2011 - 2014	<i>Desenvolvimento e Validação de um Esquema de Análise Exploratória para Dados de Química Medicinal.</i> CNPq, Processo 560119/2010-0. Coordenado pela autora.	4.1
2017 - 2019	<i>Aplicação de técnicas de transferência de aprendizagem e ontologias a modelos QSAR para regressão.</i> FAPESP-IBM, Processo 2016/18840-3.	4.1, 4.3, 5
2019 - 2020	<i>Uso de Deep Learning no Planejamento de Candidatos a Fármacos.</i> Pró-Reitoria de Pesquisa da USP. Com colaboração da autora.	4.1

Tabela 1 – Projetos de pesquisa financiados.

1.4 Organização do trabalho

O restante deste documento está organizado como segue. O Capítulo 2 descreve os fundamentos teóricos da pesquisa desenvolvida. No Capítulo 3, as atividades inerentes ao processo de descoberta de medicamentos são apresentadas em maiores detalhes, juntamente

com a metodologia de apoio baseada em IA. O Capítulo 4 discute as contribuições da autora no âmbito do desenvolvimento e aplicação de técnicas de AM para a identificação de compostos bioativos e outros propósitos relacionados. No Capítulo 5, são apresentados os resultados da construção de uma ontologia para o domínio da descoberta de medicamentos. As pesquisas atualmente desenvolvidas pela autora, considerando o tema tratado neste documento, são delineadas no Capítulo 6, juntamente com as perspectivas de trabalho no futuro próximo. Por fim, no Capítulo 7, são realizadas algumas considerações finais.

2 Conceitos fundamentais

Esse capítulo tem como objetivo apresentar alguns conceitos fundamentais empregados ao longo deste trabalho. Mais especificamente, serão descritos aspectos relacionados à formulação da técnica de regressão por vetores suporte (SVR)¹ e alguns conceitos básicos ligados ao desenvolvimento de ontologias, uma vez que estes formam a base das contribuições originais deste trabalho.

2.1 Regressão por Vetores Suporte (SVR)

O método de vetores suporte pode ser aplicado ao problema de regressão, mantendo-se todas as principais propriedades que caracterizam o algoritmo de margem máxima (VAPNIK, 1999). A extensão de SVM para o tratamento de problemas de regressão se dá pela introdução de uma função de perda (SMOLA, 1996).

Para o problema de regressão, ocorre uma reversão de propósito quando comparado à formulação de problemas de classificação binária. Ou seja, em vez de forçar as instâncias a se posicionarem o mais distante possível do hiperplano ótimo, no espaço de características, o objetivo agora é forçá-las a se posicionarem o mais próximo possível do hiperplano ótimo, não importa de que lado do hiperplano a instância se encontre. Embora os propósitos da otimização sejam opostos, o objetivo de ambas as formulações é o mesmo: maximizar a capacidade de generalização do modelo preditivo.

Formulação da técnica SVR

Dado um conjunto de dados de treinamento $\{(\mathbf{x}_i, y_i), i = 1, \dots, n\}$, em que $\mathbf{x}_i \in \mathbb{R}^d$ e $y_i \in \mathbb{R}$, o objetivo é aproximar o conjuntos de dados de treinamento com uma função linear:

$$f(\mathbf{x}) = (\mathbf{w} \cdot \mathbf{x}) + b. \quad (1)$$

¹ Do original, em inglês, *Support Vector Regression*.


Para isso, o método SVR linear encontra um modelo $\mathbf{w}$ tal que $\mathbf{w}^T \mathbf{x}_i$ é próximo do valor alvo y_i . E, isso é solucionado pela regularização do problema de otimização a seguir:

$$\min_{\mathbf{w}, \xi^*, \xi} = \frac{1}{2}(\mathbf{w}^T \mathbf{w}) + C(\sum_{i=1}^n \xi_i + \sum_{i=1}^n \xi_i^*). \quad (2)$$

Na Equação (2), o termo $(\mathbf{w}^T \mathbf{w})$ regulariza a complexidade do modelo, $C > 0$ é um parâmetro definido pelo usuário, ξ e ξ_i^* são variáveis de folga representando as restrições dos dois lados do hiperplano (veja Figura 2), conforme as equações:

$$\begin{cases} y_i - (\mathbf{w} \cdot \mathbf{x}_i) - b \leq \epsilon + \xi_i \\ (\mathbf{w} \cdot \mathbf{x}_i) + b - y_i \leq \epsilon + \xi_i^* \\ \xi_i, \xi_i^* \geq 0, \quad i = 1, \dots, n. \end{cases} \quad (3)$$

Figura 2 – Ilustração de vetores suporte para o problema de regressão com as variáveis de folga ξ e ξ^* nos dois lados do hiperplano. Figura adaptada de (LIMA, 2004).



A função de perda ϵ -insensível para o método SVR e associada a $(\mathbf{x}_i, y_i)$ é definida por:

$$L_{\epsilon\text{-insensível}}(f(\mathbf{x}) - y) = \begin{cases} 0 & \text{se } |f(\mathbf{x}) - y| < \epsilon \\ |f(\mathbf{x}) - y| - \epsilon & \text{caso contrário.} \end{cases} \quad (4)$$

A função de perda ϵ -quadrática para o método SVR e associada a $(\mathbf{x}_i, y_i)$ é definida por:

$$L_{\epsilon\text{-quadrática}}(f(\mathbf{x}) - y) = \begin{cases} 0 & \text{se } |f(\mathbf{x}) - y| < \epsilon \\ (|f(\mathbf{x}) - y| - \epsilon)^2 & \text{caso contrário.} \end{cases} \quad (5)$$

A função de perda garante que a perda é zero se $|\mathbf{w}^T \mathbf{x}_i - y_i| = |f(\mathbf{x}_i) - y_i| \leq \epsilon$. Isso significa que o valor alvo real y_i encontra-se dentro de um intervalo esperado em torno de $\mathbf{w}^T \mathbf{x}$. As duas funções apresentadas nas Equações (4 e 5) são também conhecidas como funções de perda L_1 e L_2 , respectivamente. Neste trabalho, foi utilizada a medida de erro quadrático médio (EQM)² como função de erro, que é diretamente modelada pela função de perda L_2 .

Utilizando a função de perda ϵ -quadrática, a formulação dual do modelo de regressão assume a seguinte configuração:

$$\max_{\alpha, \alpha^*} \left[-\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j)(\mathbf{x}_i \cdot \mathbf{x}_j) + \sum_{i=1}^n \alpha_i^*(y_i - \epsilon) - \alpha_i(y_i + \epsilon) \right] - \frac{1}{2C} \sum_{i=1}^n (\alpha_i^2 + (\alpha_i^*)^2). \quad (6)$$

Fazendo a seguinte substituição $\beta_i = \alpha_i - \alpha_i^*$, junto a formulação (6), viabiliza-se uma simplificação via condições de KKT, em que:

$$\alpha_i \alpha_i^* = 0 \quad i = 1, \dots, n, \quad (7)$$

o que implica em $\beta_i^2 = \alpha_i^2 + (\alpha_i^*)^2$ e $|\beta_i| = |\alpha_i - \alpha_i^*| = \alpha_i + \alpha_i^*$. Com isso, pode-se definir o problema dual considerando a função de perda L_2 como:

$$\min_{\beta} = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \beta_i \beta_j (\mathbf{x}_i \cdot \mathbf{x}_j) - \sum_{i=1}^n \beta_i y_i + \frac{1}{2C} \sum_{i=1}^n \beta_i^2 + \sum_{i=1}^n \epsilon |\beta_i|, \quad (8)$$

sujeito a:

$$\sum_{i=1}^n \beta_i = 0. \quad (9)$$

Assim, a função de regressão (1) pode ser reescrita da seguinte forma:

$$\mathbf{w} = \sum_{i=1}^n \beta_i \mathbf{x}_i \quad \text{e} \quad (10)$$

$$b = -\frac{1}{2}((\mathbf{w} \cdot \mathbf{x}_r) + (\mathbf{w} \cdot \mathbf{x}_s)). \quad (11)$$

A técnica SVR é a base de uma das contribuições originais do presente trabalho, que diz respeito ao desenvolvimento de um método de transferência de aprendizado baseado em vetores suporte e que será apresentado na Seção 4.3.

² Do original, em inglês, *Mean Squared Error*.

2.2 Ontologias

O desenvolvimento de ontologias é um tópico presente em várias áreas de pesquisa, como engenharia do conhecimento (SPOLADORE; PESSOT, 2021), processamento de língua natural (EREKHINSKAYA *et al.*, 2020), sistemas de informação cooperativos (LEAL; GUÉDRIA; PANETTO, 2019) e integração de informações (EINE; JURISCH; QUINT, 2017).


Basicamente, o papel das ontologias no processo de engenharia do conhecimento é facilitar a construção de um modelo para determinado domínio por meio da definição de um vocabulário de termos relevantes e das relações entre esses termos. Nesse sentido, as ontologias facilitam o entendimento, o compartilhamento e a reutilização de informações, visando à especificação formal e explícita de uma conceitualização consensual (GRUBER, 1995). Para que haja consenso, o desenvolvimento de uma ontologia é frequentemente um processo cooperativo envolvendo pessoas diferentes, possivelmente em locais distintos. Alternativamente, ontologias são definidas como um meio para modelar formalmente a estrutura de um sistema, identificando entidades relevantes a partir de observação, e que sejam úteis para um objetivo específico (GUARINO; OBERLE; STAAB, 2009).

A formalização do conhecimento em uma ontologia é baseada nos seguintes componentes:

1. **Classes ou conceitos:** são grupos de indivíduos que compartilham características em comum, utilizadas em um sentido amplo. São representados por termos organizados em uma taxonomia de acordo com o significado semântico. Por exemplo, em uma ontologia para descoberta de medicamentos, “alvo biológico” e “descritor químico” são conceitos importantes.
2. **Relações:** descrevem como os conceitos se relacionam. Em outras palavras, as relações representam a forma de interação entre conceitos no mesmo domínio. Relações do tipo “é-um” e “é-parte-de” são dois exemplos comuns de relações binárias.
3. **Axiomas:** representam asserções formuladas de uma forma lógica que, juntas, compreendem o conhecimento central que a ontologia descreve em seu domínio de aplicação.
4. **Instâncias:** são indivíduos que representam objetos concretos (compostos químicos, proteínas, descritores químicos).

Um outra contribuição original deste trabalho refere-se à construção de uma ontologia para o domínio da descoberta de medicamentos, denominada de OntoQSAR, a qual será apresentada no Capítulo 5. A Figura 3 mostra um fragmento dessa ontologia, no intuito de ilustrar os conceitos apresentados nesta seção. Nesse exemplo, “*Inhibitor*” e “*Algorithm*” são conceitos do domínio; “*Is a*” e “*Contains a*” expressão relações entre conceitos.

Figura 3 – Fragmento da Ontologia OntoQSAR.



3 Metodologia baseada em IA para o suporte à descoberta de medicamentos

Nesse capítulo, o processo de descoberta de medicamentos será descrito em maiores detalhes, juntamente com a apresentação da metodologia de apoio baseada em IA.

3.1 O processo de descoberta de medicamentos

O paradigma aplicado para a identificação de compostos bioativos (candidatos a medicamentos) consiste na triagem (varredura) de um grande número de compostos químicos com objetivo de encontrar aqueles que provocam uma resposta biológica desejável ao interagir com um alvo terapêutico no organismo. Estudos nessa área podem testar produtos naturais ([LACHANCE *et al.*, 2012](#)), mas grande parte das pesquisas avalia coleções de pequenas moléculas sintéticas preparadas por estratégias de química orgânica ([NIELSEN; SCHREIBER, 2008](#)). Assim, o paradigma geral da procura por novos medicamentos conta com investimentos em síntese orgânica e em testes biológicos em grandes coleções de compostos químicos.

3.1.1 Abordagens para identificação e validação do alvo biológico

Existem basicamente dois modelos usados para identificar e validar alvos biológicos: a abordagem baseada no fenótipo (ou na fisiologia da doença) e a abordagem com foco apenas no alvo, as quais diferem quanto ao modo como levam à identificação do alvo terapêutico e à seleção/otimização de pequenos compostos ([ANDRADE *et al.*, 2016](#)).

Na abordagem com foco no alvo, uma proteína-alvo é selecionada *a priori* e submetida a um processo de validação que consiste em demonstrar a relevância dessa proteína para um determinado processo biológico ou modelo de doença de interesse ([KAUSELMANN; DOPAZO; LINK, 2011](#)). Uma vez que o alvo tenha sido validado, presume-se que ligantes ou inibidores desta proteína afetarão o processo desejado.

A abordagem baseada na fisiologia consiste em testar pequenas moléculas quanto ao seu impacto nos processos biológicos, muitas vezes por meio de experimentos em células, tecidos isolados, ou mesmo em animais ([ABERLE; CREWS, 2012](#)). Essa abordagem expõe compostos químicos a proteínas em contextos biológicos mais relevantes do que a

abordagem baseada em um alvo. Uma vez que esses experimentos medem a função celular, sem impor noções pré-concebidas sobre determinados alvos e vias de sinalização relevantes, abre-se a possibilidade de descobrir novos alvos terapêuticos. É importante ressaltar que tais ensaios “pré-validam” o composto candidato e sua proteína alvo (inicialmente desconhecida) como um meio eficaz de perturbar o processo biológico ou o modelo de doença em estudo (SCHENONE *et al.*, 2013).

3.1.2 Descritores químicos

Para detectar candidatos a medicamentos com o auxílio de técnicas de AM, após a identificação e validação do alvo biológico, dados de ensaios biológicos para potenciais inibidores podem ser coletados em diversos repositórios, como ChEMBL (BENTO *et al.*, 2014), BindingDB (GILSON *et al.*, 2015) e PubChem (KIM *et al.*, 2019). Entretanto, os compostos químicos capturados nessa coleta são representados por suas estruturas 2D ou 3D, e portanto, ainda precisam ser transformados em dados numéricos, de modo a possibilitar a sua manipulação por algoritmos de aprendizado. Ferramentas específicas são utilizadas para essa finalidade, como Gaussian (FRISCH *et al.*, 2009), Padel (YAP, 2011) e Mordred (MORIWAKI *et al.*, 2018), as quais produzem, como saídas, dados chamados de descritores químicos (ou moleculares).

Young (2009) define descritores químicos como dados numéricos que representam propriedades e informações estruturais de moléculas e Montanari (2011) os classifica em vários grupos. Por exemplo, descritores constitucionais refletem a composição molecular de um composto, sem nenhuma informação sobre sua topologia; descritores geométricos capturam informações 3D, como tamanho molecular e distribuição de átomos; e descritores eletrônicos descrevem as ligações atômicas e propriedades eletrônicas da molécula. De acordo com Cherkasov *et al.* (2013), existem milhares de descritores possíveis, o que quase sempre leva à demanda por métodos de seleção de características para a redução da alta dimensionalidade.

3.1.3 Estudos de relações quantitativas estrutura-atividade

Estudos das relações estrutura-atividade (SAR)¹ são métodos clássicos da química medicinal que visam a modificar o efeito de compostos químicos bioativos por meio de alterações de suas estrutura químicas (VERMUTH; GANELLIN; LINDBERG, 1998). Esses estudos concentram-se principalmente na síntese de variantes estruturais de tais compostos, removendo ou modificando grupos funcionais e testando as alterações quanto ao seu efeito biológico. Os resultados dessas análises permitem que os pesquisadores identifiquem os grupos químicos responsáveis por induzir um efeito biológico no alvo.


Vários métodos foram propostos para análises SAR, desde a simples inspeção visual de compostos e suas atividades até métodos quantitativos, como modelos de relações quantitativas estrutura-atividade (QSAR)² e de relações quantitativas estrutura-propriedade (QSPR)³. Basicamente, as abordagens QSAR e QSPR, que são cruciais para o processo de descoberta de medicamentos, relacionam descritores químicos a valores de atividade biológica e a outras propriedades (por exemplo, absorção e metabolismo), respectivamente (GUHA, 2011). A Figura 4 apresenta um esquema geral para estudos QSAR.

¹ Do original, em inglês, Structure-Activity Relationships.

² Do original, em inglês, Quantitative Structure-Activity Relationships.

³ Do original, em inglês, Quantitative Structure-Property Relationships.

Figura 4 – Esquema geral para estudos QSAR. Os conjuntos de dados para essas análises são formados por descritores químicos que representam moléculas para as quais foram observados valores de atividade em ensaios biológicos. Esses estudos podem ser aplicados para tarefas de agrupamento, regressão ou classificação (composto ativo; inativo), caso as observações tenham sido previamente rotuladas por especialistas no domínio.



Fonte: João C. S. Souza, 2016.


As análises QSAR são amplamente utilizadas para estudar as propriedades químicas de um grupo de moléculas, a fim de descobrir grupos naturais ou prever seus níveis de atividade biológica em relação a um ou mais alvos no corpo humano (DEVILLERS; BALABAN, 2000). Para tanto, técnicas de AM podem ser aplicadas para agrupar dados ou estimar valores que indiquem a atividade biológica (por meio de técnicas de regressão) ou valores de classe (por meio de técnicas de classificação) de novos compostos químicos.

Apesar dos benefícios das análises QSAR, esses estudos são muito caros, uma vez que a transformação de descritores químicos em conjuntos de dados numéricos não é uma tarefa trivial (MICHIELAN; MORO, 2010). Em tais situações, seria desejável usar informações de outros conjuntos de dados químicos existentes para melhorar o desempenho de um modelo QSAR relacionado construído a partir de um conjunto de dados de treinamento muito pequeno. Para resolver esse problema, técnicas de transferência de aprendizado podem ser aplicadas, reduzindo o esforço dos pesquisadores e o custo do processo para gerar novos conjuntos de descritores químicos.

3.2 Metodologia proposta

A metodologia baseada em IA para suporte à descoberta de medicamentos é a apresentada na Figura 5. O processo começa com a identificação da doença e do alvo terapêutico. Em seguida, procede-se com a busca por compostos ativos que tenham sido testados quanto a sua interação com o alvo selecionado. As estruturas dos compostos coletados são, então, transformadas em descritores químicos que, por sua vez, podem passar por um processo de seleção de características para redução de dimensionalidade. Após a preparação dos dados, procede-se com a construção, avaliação e interpretação de modelos preditivos para estimar a atividade biológica de novos compostos químicos. A inovação, nesta metodologia, consiste em considerar uma ontologia do domínio QSAR para guiar a seleção de conjuntos de dados em experimentos de transferência de aprendizado, como será delineado na Seção 6.1 e para auxiliar na interpretação do modelo, a exemplo do trabalho em (LAI *et al.*, 2020), aplicado ao contexto do abuso de drogas.

Figura 5 – Metodologia baseada em técnicas de IA para o suporte à descoberta de medicamentos.



4 Técnicas de aprendizado de máquina para suporte à descoberta de medicamentos

Como resultado do surgimento de novas tecnologias, a geração de dados que dão suporte ao processo de desenvolvimento de medicamentos tornou-se mais barata, proporcionando o aumento da complexidade, diversidade e volume dos dados em um ritmo acelerado. Este cenário pode ser visto tanto na área farmacêutica quanto na área de pesquisas clínicas, em que os dados produzidos por empresas ou reunidos em repositórios de dados biológicos estão crescendo em um ritmo exponencial (FERRERO *et al.*, 2020). Em paralelo, técnicas de aprendizado de máquina (AM) têm apresentado grande potencial para acelerar a pesquisa na área de descoberta de medicamentos ao extrair informações relevantes a partir dessa vasta quantidade de dados complexos, como pode ser observado em (VATANSEVER *et al.*, 2021), (RéDA; KAUFMANN; DELAHAYE-DURIEZ, 2020) e (KIM *et al.*, 2020).

Em geral, técnicas de AM têm sido aplicadas em três estágios iniciais do processo de desenvolvimento de medicamentos:

- **Descoberta de alvos biológicos:** os métodos de AM são usados para integrar conjuntos de dados heterogêneos com o objetivo de identificar padrões que levem à compreensão dos mecanismos moleculares subjacentes à doença e ao mecanismo de ação dos medicamentos, como pode ser visto em (ZHENG *et al.*, 2019), (MADHUKAR *et al.*, 2019) e (D'SOUZA; PREMA; BALAJI, 2020).
- **Identificação e otimização de compostos bioativos:** técnicas de AM são aplicadas para gerar modelos QSAR (WANG *et al.*, 2015) e apoiar processos de automação e otimização de desenho de medicamentos (MAZIARKA *et al.*, 2020), (KONG *et al.*, 2020).
- **Análises pré-clínicas:** as abordagens de AM são empregadas na construção de modelos preditivos de propriedades físico-químicas por meio do processamento de uma grande quantidade de dados químicos e da otimização de perfis de absorção, distribuição, metabolismo, excreção e toxicidade (conhecidas como propriedades ADME-T) dos medicamentos (MALTAROLLO *et al.*, 2015), (BORRERO *et al.*, 2020).

A seguir, são descritas as contribuições mais relevantes da autora no contexto no desenvolvimento de técnicas de aprendizado de máquina e suas aplicações na área de descoberta de medicamentos.

4.1 Revisões de trabalhos relacionados

Várias publicação da autora possuem como contribuição a síntese e análise crítica de pesquisas que integram técnicas de AM ao processo de descoberta de medicamentos. Nesses trabalhos, diferentes métodos foram descritos e avaliados, de modo a disseminar o conhecimento para pesquisadores em diferentes áreas, como quimioinformática e química medicinal.

O artigo que marcou o primeiro resultado da pesquisa interdisciplinar relatada nesta monografia apresentou um amplo levantamento do estado da arte dessas investigações à época (GERTRUDES *et al.*, 2012). Nesse trabalho, aspectos relativos ao desempenho e à aplicabilidade de redes neurais perceptron multicamadas (MILAC; AVRAM; PETRESCU, 2006), redes neurais de contra-propagação (STOJÍĆ; ERIĆ; KUZMANOVSKI, 2010), redes neurais bayesianas (HOSHI *et al.*, 2006), mapas auto-organizáveis (SCHNEIDER; TANRIKULU; SCHNEIDER, 2009) e máquinas de vetores suporte (DARNAG *et al.*, 2010) ao desenvolvimento de medicamentos foram criticamente discutidos. Esse trabalho também identificou uma demanda crescente por modelos de previsão de propriedades ADME-T¹, uma vez que muitos compostos identificados como bioativos em etapas iniciais do processo falham posteriormente por não apresentar boa interação com estruturas do organismo humano (GLEESON *et al.*, 2012).

Os modelos preditivos de propriedades ADME-T podem ser vistos como uma extensão dos modelos QSAR, em que os valores a serem estimados correspondem a essas propriedades, ao invés do nível de atividade biológica. Dessa forma, é possível antecipar quais compostos candidatos a medicamentos apresentam perfis indesejáveis e, assim, reduzir a ocorrência de falhas nos testes clínicos. Buscando revelar quais métodos de AM estavam sendo utilizados para construção de modelos preditivos de propriedades ADME-T e detectar tendências e pontos críticos dessas aplicações, a autora e colaboradores realizaram um estudo que resultou na revisão apresentada em (MALTAROLLO *et al.*, 2015). O trabalho

¹ Sigla que se refere ao perfil ou processos de absorção, distribuição, metabolismo, excreção e toxicidade de uma droga após sua administração *in vivo*.

investigou a evolução do uso de técnicas de AM em análises de propriedades ADME-T e identificou quais dessas técnicas eram as mais aplicadas no momento, juntamente com as suas principais vantagens e limitações. Visando a uma melhor compreensão pelos pesquisadores da área de aplicação, o artigo mostra como devem ser entendidas as entradas e saídas dos métodos de AM no contexto das análises em questão, além de detalhar os artigos considerados mais relevantes para o estudo de cada uma das cinco propriedades ADME-T. Por fim, esse estudo também revelou uma série de ferramentas e bases de dados que podem ser usadas para análises experimentais das propriedades em questão.

Assim como ocorre em outras aplicações, o uso de métodos de AM para análise de dados de química medicinal requer atenção especial às questões relacionadas à natureza dos dados, como desbalanceamento de classes, dados incompletos, dificuldade na reconstrução de moléculas, incerteza na rotulação dos dados, entre outros (VARNEK; BASKIN, 2012). No intuito de avaliar como esses problemas vinham sendo tratados na literatura, foi realizada uma investigação que culminou na publicação de um artigo nos anais da conferência *SAI Computing Conference - 2016* (SOUZA *et al.*, 2016). A principal contribuição deste trabalho está na revisão de abordagens capazes de reduzir o impacto de dificuldades relacionadas à incerteza na rotulação de instâncias e à distribuição desbalanceada de classes, com foco nas suas aplicações em química medicinal. A justificativa para essa análise parte do fato de que não existe um método para determinar um valor de atividade biológica abaixo do qual um composto é considerado inativo. Nesse cenário, os estudos costumam produzir um pequeno grupo de instâncias com alta atividade biológica, definidas como compostos “ativos”, e outros elementos com menores níveis de atividade, formando um grupo maior de compostos “inativos”. Portanto, a definição dos rótulos negativos não é confiável, pois não há evidências concretas de que esses elementos sejam realmente inativos. Este problema tem um impacto direto nos métodos de classificação binários que dependem de classes bem definidas. Dentre as técnicas identificadas para tratar essas questões, merecem destaque abordagens baseadas em florestas aleatórias (ZHANG *et al.*, 2011) e técnicas de reamostragem (ZAKHAROV *et al.*, 2014).

Os conjuntos de dados utilizados em estudos QSAR são geralmente caracterizados por alta dimensionalidade e um pequeno número de instâncias, o que dificulta a obtenção de modelos com bom poder de generalização. Nesse contexto, técnicas de transferência de aprendizado e de aprendizado multitarefa tornam-se adequadas por aproveitar o conhecimento extraído por outros modelos QSAR para alvos biológicos idênticos ou

relacionados, reduzindo esforços e custos para avaliação de novos compostos químicos. Buscando entender melhor o funcionamento desses métodos e a extensão da aplicabilidade destes em análises QSAR, foi realizada um estudo de revisão, publicado em (SIMÕES *et al.*, 2018). Esse trabalho identificou as principais características dessas abordagens, bem como os resultados obtidos até aquele momento em pesquisas relacionadas ao desenvolvimento de medicamentos, como identificação de compostos ativos, análise de propriedades ADME-T e triagem virtual em alta escala (HTS)². Por meio desse estudo, foi possível detectar algumas lacunas que levaram ao desenvolvimento de uma técnica de transferência de aprendizado, a ser apresentada na seção, e à construção de uma ontologia para estudos QSAR, descrita na seção.

Até os dias atuais, máquinas de vetores suporte (SVM)³ (VAPNIK, 1999) é uma das técnicas de AM mais aplicadas em pesquisas na área de descoberta de medicamentos. Essa constatação motivou o desenvolvimento de mais um estudo e a publicação deste em uma revisão (MALTAROLLO *et al.*, 2018) que aborda aspectos da aplicação de métodos baseados em SVM em experimentos diversos, como em triagem virtual e na construção de modelos QSAR. O artigo apresenta a formulação da técnica SVM, discute o impacto das escolhas dos valores dos seus hiperparâmetros, como custo e função *kernel*, além de indicar os métodos mais utilizados para guiar essa busca. A questão da seleção de variáveis também é tratada nesse trabalho, uma vez que os dados utilizados para construção de modelos QSAR são frequentemente caracterizados por sua alta dimensionalidade. Vale a pena, ainda, destacar que dentre os trabalhos avaliados nessa revisão, é recorrente a crítica de que essa técnica não permite a interpretação de seus modelos, o que reforçou a justificativa de uma proposta de pesquisa, atualmente conduzida pela autora e colaboradores, de uma nova abordagem para integrar métodos de seleção de características e interpretação de modelos preditivos, a ser apresentada na seção.

Uma vez que modelos de aprendizado profundo (*deep learning*) eram (e ainda são) considerados como estado da arte em muitas aplicações, havia também a demanda em investigar como estes poderiam ser aproveitados para auxiliar atividades relacionadas ao desenvolvimento de novos medicamentos. Uma das contribuições da autora nesse sentido diz respeito à revisão apresentada em (LIPINSKI *et al.*, 2019). Dentre os pontos que

² Do original, em inglês, *High Throughput Screening*. Refere-se à busca realizada em grandes bases de dados por compostos químicos que apresentem afinidade com um determinado alvo biológico.

³ Do original, em inglês, *Support Vector Machines*.

chamaram a atenção nas análises desse trabalho, pode-se ressaltar a capacidade das técnicas de aprendizado profundo em extrair padrões de grandes volumes de dados químicos e genômicos, superando outras técnicas de AM em experimentos com essas características. Seguindo essa motivação, a autora e colaboradores conduziram uma nova investigação com foco na construção de modelos de aprendizado profundo para a identificação de compostos inibidores de um alvo terapêutico contra o câncer. Esse trabalho será discutido em maiores detalhes na seção.

O crescente surgimento de bactérias resistentes aos medicamentos disponíveis no mercado tem sido responsável pela morte de aproximadamente 700.000 pacientes em todo o mundo (GHOSH *et al.*, 2019). Considerando essa situação crítica, a procura por alternativas de curto prazo tem-se colocado como um importante desafio a ser superado. Dentre as pesquisas recentes, destacam-se aquelas que se baseiam na modificação de antibióticos já existentes e outras que visam à descoberta de novas moléculas com atividade antibacteriana. No intuito de acelerar essas investigações, cientistas têm recorrido às técnicas de AM para aplicação em experimentos de triagem virtual e modelagem QSAR. Esforços também têm sido empreendidos na busca de novos alvos terapêuticos por meio da exploração de dados de sequenciamento genético. A autora e colaboradores pruziram um estudo sobre diversos aspectos relacionados a essas análises e ao problema da descoberta de novos antibióticos, que resultou na publicação de uma revisão em (SERAFIM *et al.*, 2020). Esse trabalho realizou um resgate da história do desenvolvimento de antibióticos, discutiu as causas e os principais impactos relacionados à resistência de bactérias e identificou pesquisas em que a incorporação de métodos de AM apresentou-se como uma abordagem promissora, como pode ser visto, por exemplo, em (ARANGO-ARGOTY *et al.*, 2018).

Com o advento da pandemia de COVID-19, cientistas em todo o mundo mobilizaram-se para encontrar soluções para esse grave problema, dentre estas, pode-se citar: (i) o reposicionamento de drogas eficazes no combate a outros vírus da mesma família (como é o caso do vírus SARS-CoV); e (ii) a descoberta de novos medicamentos para o tratamento da doença. Na revisão publicada em (SERAFIM *et al.*, 2021), a autora e colaboradores descrevem as principais evidências obtidas sobre o vírus SARS-CoV-2 até aquele momento, as estratégias e abordagens computacionais recentemente aplicadas à busca de opções de tratamento, bem como os desafios para superar a COVID-19. Cabe ressaltar que, a convite do editor do periódico, esse artigo ilustra a capa da referida edição da revista.

A seguir, serão descritas outras contribuições da autora referentes ao desenvolvimento e aplicação de técnicas de AM para apoio ao processo de descoberta de medicamentos.

4.2 Modelos de consenso

Um *ensemble* permite combinar as saídas de vários modelos preditivos com o objetivo de produzir um resultado global, que pode ser visto como uma espécie de consenso entre os modelos componentes. Dessa forma, em algumas áreas, como em quimioinformática e meteorologia, é comum referir-se a um *ensemble* usando o termo “modelo de consenso”. Segundo Haykin (2009), a utilização desse tipo de abordagem pode acarretar em benefícios, como redução na variância do modelo final; melhor tolerância a ruído nos dados; e melhor poder de generalização.

4.2.1 Modelos de consenso para descoberta de medicamentos para dores neuropáticas

Dores neuropáticas são causadas por lesão ou doença do sistema somatossensorial e apresentam, como sintomas mais comuns, choque elétrico, queimação e formigamento (JENSEN *et al.*, 2011). Analgésicos, anticonvulsivantes e antiinflamatórios são exemplos de tratamentos farmacológicos usados para tratar esse tipo de dor, mas existem poucos medicamentos aprovados para essa finalidade específica (NIGHTINGALE, 2012), tornando essencial busca por novas terapias essenciais.

Receptores Sigma-1 (Sig-1R) estão distribuídos no sistema nervoso central e tecidos periféricos e são considerados um dos alvos promissores para o tratamento de dores neuropáticas e de doenças como câncer e depressão (MAURICE; SU, 2009). Em (OLIVEIRA *et al.*, 2017), foi realizado um estudo com modelos de consenso para a identificação de compostos químicos inibidores do Sig-1R. Esse trabalho comparou os resultados obtidos pelas técnicas de mínimos quadrados parciais (PLS)⁴ (WOLD, 2004) e redes neurais perceptron multicamadas (MLP)⁵ (RUMELHART; HILTON; WILLIAMS, 1986) e por modelos de consenso construídos pela combinação das saídas de modelos individuais. Foram considerados dois modelos de consenso distintos: (i) o gerado pela combinação da saídas de redes neurais MLP com diferentes funções de ativação; e (ii) o produzido pela

⁴ Do original, em inglês, *Partial Least Squares*.

⁵ Do original, em inglês, *Multilayer Perceptron*.

combinação da saída do modelo em (i) com o resultado da técnica PLS. Os experimentos conduzidos apontaram que os modelos de consenso foram superiores aos seus preditores individuais, entretanto ao se combinar a técnica PLS com o modelo de consenso das redes MLP, observou-se uma pequena queda de desempenho. Outras análises foram realizadas nesse estudo para avaliar o impacto da seleção, por especialistas, de descritores químicos na atividade dos compostos químicos avaliados.

4.2.2 Modelos de consenso para descoberta de medicamentos contra o câncer

Muitas moléculas com propriedades antimitóticas têm sido estudadas por serem capazes de matar células cancerosas, a maioria delas interagindo com os componentes dos microtúbulos⁶, como as proteínas alfa-tubulina e beta-tubulina. Durante o processo de divisão celular, os microtúbulos são responsáveis por diferentes funções, como absorção de nutrientes, disposição de organelas e separação de cromossomos em duas células-filhas durante o fuso mitótico (JORDAN; WILSON, 2004).

O trabalho em (LIPINSKI *et al.*, 2018) utiliza uma abordagem similar à apresentada na seção 4.2.1. Neste estudo, modelos de consenso baseados em PLS e redes MLP são empregados para avaliar o potencial de um grupo de compostos, denominados de chalcones (SHARMA *et al.*, 2015), como inibidores da proteína beta-tubulina, no intuito de identificar novas terapias para o combate ao câncer. Como diferencial em relação à abordagem apresentada anteriormente, nesse estudo os descritores são selecionados automaticamente por meio da utilização de algoritmos genéticos. Comparando o desempenho dos modelos, observou-se que, novamente os modelos de consenso foram superiores aos seus componentes e que a técnica PLS, combinada ao modelo de consenso formado pelas redes neurais, não levou a melhores resultados. Por outro lado, os descritores selecionados pelos algoritmos genéticos mostraram relação com o potencial de inibição (atividade biológica) dos compostos, podendo ser levados em conta em análises futuras envolvendo compostos análogos.

⁶ Microtúbulos são estruturas proteicas que fazem parte do citoesqueleto das células. Fonte: <https://brasilecola.uol.com.br/biologia/citoesqueleto.htm>

4.3 Transferência de aprendizado para regressão baseada em vetores suporte

Apesar das várias aplicações de métodos de AM em análises QSAR, o sucesso de tais abordagens depende criticamente da disponibilidade de uma grande quantidade de dados, o que permanece sendo um desafio para a área de descoberta de medicamentos. Este problema está fortemente relacionado a questões envolvendo a qualidade das fontes de dados públicas, incluindo a representação imprecisa de estruturas químicas e informações incompletas sobre os ensaios biológicos de interesse (ZHAO *et al.*, 2017). Além disso, a natureza de diferentes protocolos experimentais geralmente pode levar a dados com diferentes distribuições de probabilidade, o que torna o uso de técnicas tradicionais de AM impraticável.

Em cenários como esses, abordagens transferência de aprendizado podem ser muito úteis por extrair conhecimento a partir dados em outros domínios e aplicá-lo para melhorar o desempenho em uma tarefa alvo (ou destino) para qual poucos dados estão disponíveis. Além disso, essas abordagens conseguem superar as suposições limitantes das técnicas clássicas de aprendizado de máquina de que os dados de treinamento e teste devem pertencer ao mesmo espaço de características e seguir a mesma distribuição de probabilidade (WANG; LI, 2014). O desenvolvimento dessa abordagem foi motivado principalmente pelo fato de que as pessoas podem aplicar o conhecimento adquirido anteriormente para resolver novos problemas de modo mais rápido e com melhores soluções.

O trabalho em (SIMÕES *et al.*, 2018) propõe uma técnica de regressão por transferência de aprendizado baseada em vetores suporte e denominada de Regressão por Vetores Suporte Adaptado para Transferência de Aprendizado (SVR-ATL)⁷. O termo “adaptado” refere-se ao fato de que este método foi inspirado em uma abordagem multitarefa desenvolvida por Rosenbaum *et al.* (2013), tendo sido, portanto adaptada para o cenário de transferência de aprendizado, em que apenas dois domínios são considerados: o domínio fonte (ou origem) e o domínio alvo (ou destino).


⁷ Do original, em inglês, *Support Vector Regression - Adapted to Transfer Learning*.

A formulação do problema de otimização primal para a técnica SVR-ATL foi definida como segue:

$$\min_{\mathbf{w}_s, \mathbf{w}_t, \xi_s^*, \xi_t^*, \xi_s, \xi_t} = \frac{1}{2}(\mathbf{w}_s^T \mathbf{w}_s) + \frac{1}{2}(\mathbf{w}_t^T \mathbf{w}_t) + J(\mathbf{w}_s, \mathbf{w}_t) + \frac{c}{2} \left(\sum_{i=1}^n (\xi_{si})^2 + \sum_{i=1}^n (\xi_{si}^*)^2 \right) + \frac{c}{2} \left(\sum_{i=1}^n (\xi_{ti})^2 + \sum_{i=1}^n (\xi_{ti}^*)^2 \right). \quad (12)$$

Na Equação (12), os termos $\|\mathbf{w}_s\|^2$, $\|\mathbf{w}_t\|^2$ controlam a complexidade do modelo da tarefa específica, como acontece para o método SVR padrão. A função $J(\mathbf{w}_s, \mathbf{w}_t)$ representa o termo de regularização adicional que aumenta a semelhança dos vetores de pesos das tarefas de origem e destino. Assim, a transferência de aprendizado é alcançada ao impor que a função f_t seja mais semelhante a função f_s . Uma ilustração de como a técnica transfere o conhecimento entre as tarefas é apresentada na Figura 6.

Figura 6 – Ilustração do conhecimento transferido a partir da tarefa de origem, que contém uma grande quantidade de dados de treinamento (verde) para uma tarefa de destino, que contém poucos dados de treinamento (azul). Os tubos ϵ -sensível ao redor das funções de regressão $\mathbf{w}_s^T \mathbf{x}$ e $\mathbf{w}_t^T \mathbf{x}$ são descritos pelas linhas tracejadas. Figura adaptada de (ROSENBAUM *et al.*, 2013).



Na Figura 6, o termo regularizador $J(\mathbf{w}_s, \mathbf{w}_t)$ torna o modelo da tarefa de destino ($\mathbf{w}_t$) mais semelhante ao modelo da tarefa de origem ($\mathbf{w}_s$). Com isso, um modelo $\mathbf{w}_t$ que é mais semelhante ao modelo $\mathbf{w}_s$ possui melhor poder de predição para dados desconhecidos, o que resulta em uma melhor generalização do modelo. Maiores detalhes sobre a derivação do método SVR-ATL podem ser encontrados em (SIMÕES, 2018).

Em (SIMÕES *et al.*, 2018), a técnica SVR-ATL foi empregada na construção de modelos QSAR para diferentes alvos biológicos e doenças. Assim, foram considerados seis pares (fonte, destino) de conjuntos de dados, sendo cada par relacionado a um alvo particular, como segue:

- Receptor ALK-5⁸ (ARAUJO *et al.*, 2015), que é um alvo muito utilizado para o tratamento do câncer.
- Receptor PPAR⁹-alfa, relacionado ao metabolismo de lipídios e carboidratos (MALTAROLLO; HONORIO, 2012).
- Receptor PPAR-delta, que regula o metabolismo de lipídios e a resistência à insulina.
- Receptor DHFR¹⁰, que é uma enzima associada ao tratamento do câncer e doenças inflamatórias (MENDES *et al.*, 2010).
- Enzima ciclooxygenase (COX), associada ao tratamento de doenças inflamatórias (HILÁRIO; TERRERI; LEN, 2006).
- Receptores do estrogênio (ER)¹¹, relacionados ao tratamento de distúrbios hormonais (SUTHERLAND; O'BRIEN; WEAVER, 2003).

Os experimentos conduzidos revelaram que a técnica SVR-ATL pode aprimorar os resultados de regressão, em comparação com aqueles obtidos pelo método SVR tradicional, especialmente quando o número de instâncias no conjunto de destino é muito reduzido.

Entretanto, uma dificuldade encontrada nesse trabalho é que, para que a transferência de aprendizado seja benéfica, é necessário que os conjuntos de dados estejam relacionados de alguma forma (PAN; YANG, 2010), o que não pode ser avaliado automaticamente para conjuntos de dados químicos. Segundo Girschick, Rückert e Kramer (2012), esse problema poderia ser minimizado caso existissem metadados (por exemplo, dados de ontologia) relacionando as diferentes variáveis em dados químicos e biológicos, de modo a guiar a busca por conjuntos relacionados. Dada essa necessidade, a autora idealizou a construção de uma ontologia para estudos QSAR, a ser apresentada no capítulo 5, para dar suporte a essa solução e também à integração de diferentes conjuntos de dados.

⁸ Do original, em inglês, *activin receptor-like kinase 5*.

⁹ Do original, em inglês, *peroxisome proliferator-activated receptors*.

¹⁰ Do original, em inglês, *dihydrofolate reductase*.

¹¹ Do original, em inglês, *estrogen receptors*.

4.4 Técnicas de aprendizado profundo

Como mais recente contribuição, o trabalho apresentado em (ESPINOZA *et al.*, 2021), avaliou o desempenho de modelos de aprendizado profundo, em comparação com florestas aleatórias e regressão por vetores suporte, para prever a atividade biológica de inibidores do alvo ALK-5 como candidatos ao tratamento de câncer. Mais especificamente, foram consideradas redes neurais com arquitetura *feedforward* e neurônios ocultos com função de ativação ReLU, além de regularização *dropout* e estratégia de parada prematura *early stop*. Os modelos foram treinados com moléculas coletadas do repositório ChEMBL e avaliados com procedimentos de validação interna e externa. Nas análises experimentais conduzidas nesse estudo, os modelos de aprendizado profunda apresentaram resultados superiores aos dois outros métodos de AM.

5 OntoQSAR - Uma ontologia para apoio a descoberta de medicamentos

Uma outra contribuição importante apresentada nesta monografia refere-se ao desenvolvimento e validação da ontologia OntoQSAR, que integra conceitos químicos e biológicos considerados relevantes em análises QSAR. Os resultados obtidos após a avaliação dessa ontologia em um estudo de caso sobre o câncer foram apresentados em (ANGELO *et al.*, 2020).

5.1 Motivação para o desenvolvimento da OntoQSAR

A motivação para a proposta de construção da OntoQSAR originou-se na detecção de duas lacunas encontradas na literatura. A primeira diz respeito à falta de ontologias para guiar a busca por conjuntos de origem em sistemas de transferência de aprendizado; e a outra está associada a uma demanda crescente na área de descoberta de medicamentos por modelos preditivos interpretáveis. A seguir esses problemas são descritos em maiores detalhes.

5.1.1 Falta de metadados para relacionar conceitos em estudos QSAR

Uma das premissas para a utilização de técnicas de transferência de aprendizado é que os domínios de origem e de destino devem ser relacionados. Em (TAN *et al.*, 2015), os autores afirmam que essa relação pode ser estabelecida considerando instâncias ou características dos conjuntos de dados. Se nenhuma relação direta for encontrada, a transferência forçada não vai funcionar, não resultando em melhora ou até mesmo piorando o desempenho do modelo no domínio de destino (FITZGERALD; THOMAZ, 2015), fato conhecido como transferência negativa (WANG; LI, 2014).

Considerando a análise de dados de natureza química, em (GIRSCHICK; RUCKERT; KRAMER, 2013) foi proposta uma abordagem para selecionar conjuntos de dados de origem de forma orientada a dados a partir de repositórios públicos. Os autores utilizaram o repositório de dados PubChem (KIM *et al.*, 2019), que contém mais de 500 mil conjuntos de dados obtidos a partir de experimentos toxicológicos e bioquímicos. Esse trabalho aponta que um problema comum em dados de natureza química refere-se à falta de metadados (por exemplo, dados de ontologia) para relacionar as variáveis em

diferentes conjuntos de dados. Portanto, sugere-se incorporar ao processo de aprendizado uma metodologia que possa explorar os metadados existentes em ontologias para inferir a relação entre conjuntos de dados químicos e assim, aprimorar os experimentos com tais conjuntos de dados.

5.1.2 Falta de interpretabilidade em algumas aplicações de AM

Segundo [Griffen et al. \(2018\)](#), a falta de interpretabilidade é mais um desafio em várias aplicações de algoritmos de AM na área de química medicinal. Os autores argumentam que é muito difícil expor quais fatores (em termos químicos, quais subestruturas) estão conduzindo a estimativa gerada pelo algoritmo. Refletiram, ainda, sobre o problema do ponto de vista humano, em que um usuário sentir-se pouco confiante ao se deparar com “fazer o que a máquina diz” ou não, mas sem que haja um método para avaliar a validade da previsão. Por fim, os autores argumentam que essas limitações podem desacelerar a adoção de métodos de AM em aplicações científicas.

Mais recentemente, essa lacuna foi reiterada por [Sessions et al. \(2020\)](#), que argumentam que apesar de vários bancos de dados públicos disponibilizarem informações referentes a ensaios biológicos, alvos e compostos químicos, estes repositórios não empregam os mesmos critérios para seleção ou classificação de dados e nem utilizam ontologias do domínio.

Identificadas essas lacunas, autora idealizou a proposição de uma ontologia para representar o conhecimento que baseia os estudos QSAR.


5.2 Desenvolvimento da ontologia

Para criar a OntoQSAR, foi utilizada a metodologia SABiO (Systematic Approach for Building Ontologies), proposta em ([FALBO, 2014](#)), cujo objetivo é fornecer uma base sólida para a modelagem de conceitos. A Figura 7 ilustra as cinco etapas principais da SABiO: identificação de propósitos e elicitação de requisitos; captura e formalização de ontologias; desenho; implementação; e teste (ou validação). Além disso, processos de apoio podem ser executados paralelamente ao processo de desenvolvimento principal. A aplicação da metodologia SABiO no contexto deste projeto será detalhada a seguir.

5.2.1 Identificação dos propósitos da ontologia e levantamento de requisitos

Essa etapa visa a identificar os objetivos e possíveis aplicações da ontologia, bem como qualquer requisito (funcional e não funcional) relacionado a seu desenvolvimento. As questões de competência (CQs)¹ são ferramentas essenciais para determinar esses requisitos e quaisquer sub-ontologias que precisam ser desenvolvidas.

Figura 7 – Metodologia utilizada para desenvolver a ontologia OntoQSAR. Adaptado de (FALBO, 2014).



A ontologia OntoQSAR pretende representar o domínio QSAR com o objetivo de integrar várias bases de conhecimento diferentes e criar um ambiente em que os pesquisadores possam obter facilmente informações para serem utilizadas em seus experimentos de descoberta de medicamentos. A especialista no domínio QSAR, participante deste projeto, identificou 60 CQs, por meio das quais foi possível estruturar o primeiro desenho da ontologia envolvendo conceitos e propriedades relacionadas ao alvo ALK-5, uma vez que este é considerado no estudo de caso deste projeto. Exemplos de CQs levantadas para o desenvolvimento da ontologia OntoQSAR são apresentadas na Tabela 2.

¹ Do original, em inglês, *competency questions*.

Questões simples
CQ1: Quais inibidores atravessam a barreira hematoencefálica?
CQ2: Quais inibidores já estão disponíveis comercialmente?
CQ3: Quais inibidores têm o grupo funcional cetona?
CQ4: Quais inibidores foram estudados em modelagem 2D QSAR?
Questões complexas
CQ5: Em quais publicações testes <i>in vivo</i> com propriedades farmacocinéticas calculadas podem ser encontrados?
CQ6: Quais inibidores foram testados com relação alvo biológico ALK-5 e estão na fase II?
CQ7: Quais inibidores possuem dados de <i>docking</i> e testes <i>in vitro</i> ?
CQ8: Quais inibidores violam a regra de Lipinsk?

Tabela 2 – Questões de competência para a ontologia OntoQSAR.

5.2.2 Coleta e formalização da ontologia

Esta fase consiste em definir os termos que são considerados relevantes para o domínio de descoberta de medicamentos e em categorizá-los em classes, subclasses, propriedades e indivíduos. Baseando-se na ideia de que a OntoQSAR pode ser estendida ou ainda contribuir para o desenvolvimento de outras ontologias relacionadas, foi dada atenção especial à elaboração da sua estrutura inicial quanto aos descritores químicos e dados biológicos, a fim de permitir a inclusão de informações adicionais sobre compostos ainda não observados. Portanto, essa etapa pode ser vista como uma modelagem conceitual que visa a representar o domínio em questão com base nas CQs. A utilização de linguagens expressivas, como o OntoUML [25], é crucial para criar ontologias axiomatizadas, tornando a representação o mais próximo possível da realidade.

A construção da ontologia foi iniciada por meio da definição de conceitos relevantes no domínio de modelagem QSAR, os quais formariam a base da ontologia. Pesquisando a literatura sobre descoberta de medicamentos e química medicinal, foi criada uma lista de termos que representam conceitos, relações entre os termos e quaisquer propriedades que os conceitos possam apresentar. Alguns desses termos foram incluídos na OntoQSAR pela reutilização de ontologias existentes. O próximo passo foi a estruturação/conceitualização da ontologia (em classes, subclasses e atributos), em que todos os conceitos considerados importantes foram inseridos ou reutilizados, para fosse possível interconectá-los.

A ontologia OntoQSAR foi formalizada inicialmente utilizando a linguagem OntoUML e o software OLED (*OntoUML lightweight editor*) (GUERSON *et al.*, 2015), que é um ambiente para desenvolvimento, avaliação e implementação de ontologias. É importante

mentonar que existe uma relação direta entre essa etapa e a anterior, à medida que novas CQs são geradas e novos axiomas precisam ser implementados.


5.2.3 Projeto da ontologia

Nessa etapa de refinamento, foram considerados aspectos computacionais. Mais especificamente, o gráfico OntoUML foi exportado para uma extensão OWL e o software Protégé² foi utilizado para manipular a ontologia a partir de então. Por fim, as cardinalidades entre as classes e subclasses, bem como os prefixos dos conceitos, foram incluídos na ontologia.

A Figura 8 mostra parte da OntoQSAR com oito classes (destacadas em azul), 29 subclasses (em verde) e as restrições de cardinalidade, que também são descritas na Tabela 3 para algumas relações entre conceitos. Um fragmento da OntoQSAR, produzido usando a ferramenta Protégé, pode ser visto na Figura 9.

² Disponível em: <http://protege.stanford.edu/>.


Figura 8 – Visão parcial da OntoQSAR com oito classes e 29 subclasses.



Um inibidor possui pelo menos um e no máximo n grupos funcionais.
Um grupo funcional pode estar presente em n inibidores.
Um inibidor tem pelo menos um e no máximo n testes experimentais.
Um teste experimental pode ter n inibidores.
Um inibidor tem pelo menos uma e no máximo n publicações.
Uma publicação pode ter n inibidores.
Um algoritmo pode gerar pelo menos um e no máximo n modelos QSARs.
Uma característica farmacocinética possui pelo menos um e no máximo n inibidores.
Um inibidor contém pelo menos uma e no máximo n características farmacocinéticas.
Um grupo farmacofórico possui pelo menos um e no máximo n inibidores.
Um inibidor possui exatamente um grupo farmacofórico.

Tabela 3 – Algumas restrições de cardinalidade da ontologia OntoQSAR.

Figura 9 – Um fragmento da ontologia OntoQSAR produzido pela ferramenta Protégé.



Validação da ontologia

O estudo de caso considerado teve como foco compostos químicos com atividade biológica em relação ao receptor ALK-5, um dos alvos mais investigados em terapias de combate ao câncer. Inicialmente, foi realizada uma revisão de literatura para identificar estudos que apresentam dados sobre moléculas inibidoras do alvo biológico ALK-5, a fim de que fosse possível listar conceitos químicos e biológicos relevantes, entre outros relacionados ao domínio QSAR. Essa investigação resultou em 54 artigos e 750 inibidores (candidatos a medicamentos), encontrados nas bases de dados Web of Science³ e PubChem (KIM *et al.*, 2019), respectivamente.

Em seguida, as estruturas de todos os inibidores encontrados foram construídas utilizando as ferramentas Avogadro⁴, Chems sketch⁵ e Open Babel (O'BOYLE *et al.*, 2011). Os resultados foram registrados nos formatos 2D, 3D e Smiles [31] para que fosse possível usá-los como entrada para outras ferramentas computacionais, como Gaussian (O'BOYLE, 2012), Padel (YAP, 2011), Mordred (MORIWAKI *et al.*, 2018), pkCSM

³ Disponível em: <https://www.webofknowledge.com>.

⁴ Disponível em: <https://avogadro.cc>.

⁵ Disponível em: <https://www.acdlabs.com/resources/freeware/chemsketch/>.

(PIRES; BLUNDELL; ASCHER, 2015) e SwissADME (DAINA; MICHELIN; ZOETE, 2017), que calcularam os descritores químicos para cada composto no conjunto de dados. Vale ressaltar que tais descritores referem-se principalmente a características eletrônicas e estereoquímicas extraídas da estrutura molecular dos compostos selecionados. No próximo passo, os dados de cada molécula foram associados ao seu valor correspondente de atividade biológica com relação ao alvo, o qual foi estimado experimentalmente. Finalmente, informações adicionais relevantes sobre compostos químicos também foram extraídas dos testes biológicos disponíveis, juntamente com as propriedades das técnicas aplicadas nas análises correspondentes.

A ontologia OntoQSAR foi então populada com os dados gerados, resultando em uma representação formal do domínio em questão e que poderá ser utilizada em uma comunicação compartilhada. Para validar a ontologia em relação aos dados do receptor ALK-5, a linguagem SPARQL⁶ foi utilizada para consultar os dados anotados, a fim de simular operações de consulta SQL.

As seguintes perguntas foram elaboradas e posteriormente transformadas em consultas SPARQL, a fim de validar a ontologia OntoQSAR:

- Q1: Quais inibidores têm um valor de massa molecular menor que 500?
- Q2: Quais inibidores violam a regra de Linski?
- Q3: Quais inibidores atravessam a barreira hematoencefálica?

Os dados recuperados da ontologia utilizando o editor de consultas SPARQL foram avaliados quanto à consistência pela especialista no domínio e foram todos considerados registros válidos e consistentes.

Como trabalho futuro, pretende-se estender esse processo de validação para incluir consultas mais complexas que também possam envolver vários relacionamentos entre os conceitos da ontologia.

⁶ Disponível em: <http://www.w3.org/TR/rdf-sparql-query/>.

6 Trabalhos em andamento e perspectivas

Esse capítulo tem por finalidade descrever os trabalhos de pesquisa que estão sendo desenvolvidos pela autora, assim como algumas perspectivas no futuro próximo.

6.1 *Busca semântica por conjuntos de dados de origem em experimentos de transferência de aprendizado*

O trabalho aqui apresentado refere-se à utilização de ontologias e medidas de similaridade semântica para auxiliar no processo de seleção de conjuntos de dados de origem em experimentos de transferência de aprendizado. Esta proposta está sendo implementada no âmbito de uma pesquisa de mestrado orientada pela autora.


A ideia teve inspiração no trabalho desenvolvido em (JIANG *et al.*, 2019), o qual propõe uma metodologia para busca por conjuntos de dados governamentais abertos, em que a semântica dos dados depende dos metadados que os descrevem. Nessa abordagem, os autores realizaram a vinculação dos conjuntos de dados aos conceitos de uma ontologia, permitindo a realização de buscas baseadas na estrutura hierárquica desta representação e no cálculo de medidas de similaridade.

De forma similar a (JIANG *et al.*, 2019), a proposta elaborada pela prevê que os conceitos que representam um conjunto de dados tabular sejam extraídos a partir de seus metadados. Em princípio, apenas os atributos dos conjuntos serão utilizados como metadados, mas descrições textuais destes, juntamente com *corpora* relacionados à área de química medicinal, também serão considerados em uma etapa posterior. Uma vez que o contexto deste trabalho refere-se a estudos QSAR, os conceitos extraídos encontrarão seus correspondentes na ontologia OntoQSAR, apresentada no capítulo 5.

Como ilustrado na Figura 10, a cada conjunto de dados, armazenado em um repositório local, será atribuído um vetor de similaridade entre este conjunto e os conceitos da ontologia, o qual será designado por CDSV¹. Um vetor de conceitos será construído para cada uma das medidas de similaridade consideradas em (MCINNES; PEDERSEN, 2015).

¹ Do original, em inglês, Concept-Dataset Similarity Vector.

Figura 10 – Exemplo de um vetor de similaridade entre um conjunto de Dados D_1 e os conceitos de uma ontologia.



Também será calculada uma matriz de similaridades entre os conceitos da ontologia, denotada por CCSM², que será utilizada na normalização do vetor CDSV. Ressalta-se que haverá uma matriz para cada medida de similaridade considerada na.

Para avaliar os resultados de similaridade obtidos nessa etapa, estes serão comparados com avaliações realizadas por especialistas do domínio. Mais especificamente, serão apresentados a esses especialistas alguns pares de conceitos presentes na ontologia OntoQSAR, aos quais os colaboradores devem atribuir um valor de similaridade entre 0 e 10. Os resultados dessa avaliação serão, então, confrontados com aqueles obtidos pelo cálculo das medidas de similaridade, utilizando-se para isso o coeficiente de Spearman (MYERS; WELL; LORCH, 2013), tal como realizado em (MCINNES; PEDERSEN, 2015).

Após a avaliação por especialistas, procede-se com o desenvolvimento do sistema propriamente dito, que deverá funcionar da maneira como segue. A partir da definição de uma determinada tarefa alvo em um problema de transferência de aprendizado, toma-se o

² Do original, em inglês, *Concept-Concept Similarity Matrix*.

conjunto de dados no domínio alvo e apresenta-se os seus metadados como entrada para o sistema. A partir disso, ocorrerá a busca semântica por conjuntos de dados relacionados, dentre aqueles armazenados no repositório local. O resultado dessa busca será uma lista de ranqueamentos dos conjuntos armazenados, de acordo com as medidas de similaridade calculadas.

O resultado final obtido pelo sistema será avaliado de forma indireta, observando-se o desempenho da técnica de transferência de aprendizado. Ou seja, espera-se aqui que os conjuntos identificados automaticamente como mais similares funcionem como domínios-fonte de forma satisfatória. Para isso, serão realizados experimentos de transferência de aprendizado, tomando-se os conjuntos de dados no topo do ranqueamento obtido por cada medida de similaridade. Os resultados produzidos por essas análises serão discutidos em um estudo comparativo, em que serão observadas a adequação de cada medida considerada e a validade da proposta aqui apresentada.

Ressalta-se que, em um primeiro momento, a técnica SVR-ATL ([SIMÕES et al., 2018](#)) será o método de transferência de aprendizado considerado nesses experimentos. Entretanto, a utilização de outras técnicas com o mesmo propósito são consideradas como perspectivas de trabalhos futuros.


6.2 Desenvolvimento de um sistema para avaliação e interpretação de resultados QSAR

Esse trabalho se refere à utilização de métodos de IA explicável como apoio ao processo de seleção de características em estudos QSAR, resultando em uma abordagem que combina interpretabilidade e redução de dimensionalidade. Para isso, a técnica LIME³ ([RIBEIRO; SINGH; GUESTRIN, 2016](#)) será utilizada, em combinação com diferentes métodos de seleção de características, para geração de modelos QSAR interpretáveis.

A motivação para essa proposta consiste em aproveitar o conhecimento de especialistas do domínio para avaliar resultados de interpretação de previsões que irão retro-alimentar a entrada de métodos de seleção de características de modo cíclico, até que explicações coerentes para o contexto sob análise sejam geradas e o modelo preditivo apresente resultado satisfatório, de acordo com uma medida que também será proposta nessa pesquisa. Uma visão geral da abordagem proposta pode ser vista na figura 11.

³ Do original, em inglês, *Local Interpretable Model-agnostic Explanations*.

Figura 11 – Visão geral do sistema proposto para avaliação e interpretação de resultados QSAR.



Como primeiro passo nessa análise, descritores moleculares numéricos serão gerados a partir de estruturas de compostos químicos coletados em repositórios de dados públicos. Aos descritores, somam-se os dados de atividade biológica obtidos a partir de bioensaios em que os compostos sob análise foram testados com relação a suas interações com determinados alvos terapêuticos no organismo. Essa etapa será executada em parceria com a Profa. Káthia Honório e seus alunos, integrantes do grupo de pesquisa GrIA⁴, que farão o papel de especialistas do domínio nessa pesquisa.

Uma vez gerados os conjuntos de dados para construção e avaliação dos modelos QSAR, inicia-se o processo integrado, que envolve um esquema cíclico de modelagem

⁴ Grupo de Inteligência Artificial (<http://www.each.usp.br/gria/>).

QSAR, validação do modelo preditivo, geração de explicações e avaliação integrada, a qual resultará em um *score* refletindo a qualidade da explicação e o desempenho do modelo. Esse processo iterativo é repetido até que os modelos e as explicações resultem em um *score* satisfatório.

Para a etapa de seleção de descritores, métodos diversos serão considerados, em especial, técnicas *wrapper* e de filtro. O passo de modelagem QSAR considerará as técnicas de regressão por vetores suporte, redes neurais MLP e florestas aleatórias. Para cada um desses métodos, uma etapa preliminar será executada para seleção de hiperparâmetros, utilizando técnicas como busca em grade ou busca aleatória.

Após a construção dos modelos QSAR, estes serão avaliados utilizando um conjunto de validação externa (não visto durante as fases de treinamento e seleção de parâmetros).

6.3 Perspectivas futuras

Além da conclusão dos trabalhos descritos neste capítulo, a autora pode mencionar como perspectivas, em um futuro próximo, as seguintes investigações:

- A extensão do processo de validação da ontologia OntoQSAR para incluir consultas mais complexas e que também possam envolver vários relacionamentos entre os conceitos da ontologia, tal como comentado no Capítulo 5;
- A incorporação de ontologias ao processo de interpretação de modelos de aprendizado de máquina; e
- A integração de dados químicos e genômicos para construção de modelos QSAR.

7 Conclusões

Esta monografia discutiu várias abordagens de IA que podem ser usadas para apoiar o processo de descoberta de novos medicamentos, de modo a reduzir o tempo e os custos envolvidos nas suas atividades. Dentre as técnicas avaliadas neste documento, destacam-se os métodos de aprendizado de máquina para identificação de compostos bioativos e ontologias de domínio que possam ser aplicadas para a integração de dados de diferentes naturezas.

Dentre as principais contribuições apresentadas pela autora, pode-se mencionar: (i) o desenvolvimento de uma técnica de transferência de aprendizado e sua aplicação em estudos QSAR envolvendo diferentes alvos biológicos; (ii) a construção de uma ontologia, que teve como objetivo integrar conceitos químicos e biológicos e inter-relações relevantes no domínio QSAR; e (iii) a elaboração de uma série de trabalhos de revisão que investigam como diferentes abordagens de aprendizado de máquina podem beneficiar as pesquisas em descoberta de medicamentos, disseminando o conhecimento sobre essas técnicas para pesquisadores de diversas áreas.

Além disso, foram delineadas novas propostas, como uma abordagem de busca semântica por conjuntos de origem em aplicações de transferência de aprendizado e um sistema para integrar seleção de características e interpretação de resultados de modelos QSAR.

Vários são os desafios encontrados em pesquisas na área de descoberta de medicamentos, como a questão da alta dimensionalidade, a falta de integração entre as bases de dados e a demanda crescente por modelos preditivos interpretáveis por humanos. Assim, acredita-se que ainda há muito a ser explorado quanto à incorporação de abordagens inteligentes às investigações nesse cenário, que requer, de modo crucial, o mínimo entendimento de seus processos por pesquisadores da área de Computação.

Referências

- ABERLE, N.; CREWS, C. Exploring biology with small organic molecules. *Chemical Genomics*, p. 10–25, 2012. Citado na página 20.
- ANDRADE, E.; BENTO, A. F.; CAVALLI, J.; OLIVEIRA, S. K.; FREITAS, C. S.; MARCON, R.; SCHWANKE, R. C.; SIQUEIRA, J. M.; CALIXTO, J. Non-clinical studies required for new drug development – part i: Early in silico and in vitro studies, new target discovery and validation, proof of principles and robustness of animal studies. *Brazilian Journal of Medical and Biological Research*, v. 49, 2016. Citado na página 20.
- ANGELO, R. M.; IO, A. K.; ALMEIDA, M. P.; SILVEIRA, R. G.; OLIVEIRA, P. R.; ALCAZAR, J. J. P.; HONORIO, K. M.; BETTANIN, F. OntoQSAR: an ontology for interpreting chemical and biological data in quantitative structure-activity relationship studies. In: *The 14th IEEE International Conference on Semantic Computing (ICSC)*. San Diego, USA: [s.n.], 2020. p. 203–206. Citado na página 36.
- ARANGO-ARGOTY, G.; GARNER, E.; PRUDEN, A.; HEATH, L. S.; VIKESLAND, P.; ZHANG, L. Deeparg: a deep learning approach for predicting antibiotic resistance genes from metagenomic data. *Microbiome*, v. 6, n. 23, 2018. Citado na página 29.
- ARAÚJO, S. C.; MALTAROLLO, V. G.; SILVA, D. C.; GERTRUDES, J. C.; HONORIO, K. M. Alk-5 inhibition: a molecular interpretation of the main physicochemical properties related to bioactive ligands. *Journal of the Brazilian Chemical Society*, SciELO Brasil, v. 26, n. 9, p. 1936–1946, 2015. Citado na página 34.
- BENTO, A. P.; GAULTON, A.; HERSEY, A.; BELLIS, L.; CHAMBERS, J.; DAVIES, M.; KRÜGER, F. A.; LIGHT, Y.; MAK, L.; MCGLINCHEY, S.; NOWOTKA, M.; PAPADATOS, G.; SANTOS, R.; OVERINGTON, J. P. The chEMBL bioactivity database: an update. *Nucleic Acids Research*, v. 42, p. D1083 – D1090, 2014. Citado na página 21.
- BORRERO, L. A.; GUETTE, L. S.; LOPEZ, E.; PINEDA, O. B.; CASTRO, E. B. Predicting toxicity properties through machine learning. *Procedia Computer Science*, v. 170, p. 1011–1016, 2020. Citado na página 25.
- CARRARA, L.; LAVEZZI, S. M.; BORELLA, E.; NICOLAU, G. D.; MAGNI, P.; POGGESI, I. Current mathematical models for cancer drug discovery. *Expert Opinion on Drug Discovery*, v. 12, n. 8, p. 785–799, 2017. Citado na página 10.
- CHERKASOV, A.; MURATOV, E.; FOURCHES, D.; VARNEK, A.; BASKIN, I.; CRONIN, M.; DEARDEN, J.; GRAMATICA, P.; MARTIN, Y.; TODESCHINI, R.; CONSONNI, V.; KUZ'MIN, V.; CRAMER, R.; BENIGNI, R.; YANG, C.; RATHMAN, J.; TERFLOTH, L.; GASTEIGER, J.; RICHARD, A.; TROPSHA, A. QSAR modeling: Where have you been? where are you going to? *Journal of medicinal chemistry*, v. 57, 2013. Citado na página 21.
- DAINA, A.; MICHIELIN, O.; ZOETE, V. SwissADME: a free web tool to evaluate pharmacokinetics, drug-likeness and medicinal chemistry friendliness of small molecules. *Scientific Reports*, v. 7, n. 42717, 2017. Citado na página 43.

- DARNAG, R.; MAZOUZ, E. M.; SCHMITZER, A.; VILLEMIN, D.; JARID, A.; CHERQAOUI, D. Support vector machines: Development of QSAR models for predicting anti-HIV-1 activity of TIBO derivatives. *European journal of medicinal chemistry*, v. 45, p. 1590–1597, 2010. Citado na página 26.
- DEVILLERS, J.; BALABAN, A. T. *Topological indexes and related descriptors in QSAR and QSPAR*. [S.l.]: CRC Press, 2000. Citado na página 23.
- DIMASIA, J. A.; GRABOWSKIB, H. G.; HANSEN, R. W. Innovation in the pharmaceutical industry: New estimates of r&d costs. *Journal of Health Economics*, v. 47, p. 20–33, 2016. Citado na página 10.
- D'SOUZA, S.; PREMA, K.; BALAJI, S. Machine learning models for drug-target interactions: current knowledge and future directions. *Drug Discovery Today*, v. 25, p. 748–756, 2020. Citado na página 25.
- EINE, B.; JURISCH, M.; QUINT, W. Ontology-based big data management. *Systems*, v. 5, n. 3, 2017. Citado na página 18.
- EREKHINSKAYA, T.; STREBKOV, D.; PATEL, S.; BALAKRISHNA, M.; TATU, M.; MOLDOVAN, D. Ten ways of leveraging ontologies for natural language processing and its enterprise applications. In: *Proceedings of The International Workshop on Semantic Big Data*. [S.l.]: Association for Computing Machinery, 2020. (SBD '20). Citado na página 18.
- ESPINOZA, G. Z.; ANGELO, R. M.; OLIVEIRA, P. R.; HONORIO, K. M. Evaluating deep learning models for predicting alk-5 inhibition. *PLoS ONE*, v. 16, 2021. Citado na página 35.
- FALBO, R. Abio: Systematic approach for building ontologies. In: *Proceedings of the 1st Joint Workshop on Ontologies in Conceptual Modeling and Information Systems Engineering co-located with 8th International Conference on Formal Ontology in Information Systems (FOIS 2014)*. [S.l.: s.n.], 2014. Citado 3 vezes nas páginas 5, 37 e 38.
- FERRERO, E.; BRACHAT, S.; JENKINS, J. L.; MARC, P.; SKEWES-COX, P.; ALTSHULER, R. C.; KELLER, C. G.; KAUFFMANN, A.; SASSAMAN, E. K.; LARAMIE, J. M.; SCHOEBERL, B.; BOROWSKY, M. L.; STIEFL, N. Ten simple rules to power drug discovery with data science. *PLOS Computational Biology*, v. 16, n. 8, p. 1–10, 2020. Citado na página 25.
- FITZGERALD, T.; THOMAZ, A. L. Skill demonstration transfer for learning from demonstration. In: *Proceedings of the Tenth Annual ACM/IEEE International Conference on Human-Robot Interaction Extended Abstracts*. [S.l.]: ACM, 2015. p. 187–188. Citado na página 36.
- FRISCH, M.; TRUCKS, G.; SCHLEGEL, H.; SCUSERIA, G.; ROBB, M.; CHEESEMAN, J.; SCALMANI, G.; BARONE, V.; MENNUCCI, B.; PETERSSON, G.; NAKATSUJI, H.; CARICATO, M.; LI, X.; HRATCHIAN, H.; IZMAYLOV, A.; BLOINO, J.; ZHENG, G.; SONNENBERG, J.; HADA, M.; FOX, D. Gaussian 09 (revision a02). *Gaussian Inc. Wallingford CT*, 2009. Citado na página 21.
- GERTRUDES, J. C.; MALTAROLLO, V. G.; SILVA, R. A.; OLIVEIRA, P. R.; HONÓRIO, K. M.; SILVA, A. B. F. Machine learning techniques and drug design. *Current medicinal chemistry*, v. 19, p. 4289–4297, 2012. Citado na página 26.

GHOSH, C.; SARKAR, P.; ISSA, R.; HALDAR, J. Alternatives to conventional antibiotics in the era of antimicrobial resistance. *Trends in microbiology*, v. 27, p. 323–338, 2019. Citado na página 29.

GILSON, M.; LIU, T.; BAITALUK, M.; NICOLA, G.; HWANG, L.; CHONG, J. Bindingdb in 2015: A public database for medicinal chemistry, computational chemistry and systems pharmacology. *Nucleic acids research*, v. 44, 2015. Citado na página 21.

GIRSCHICK, T.; RÜCKERT, U.; KRAMER, S. Adapted transfer of distance measures for quantitative structure-activity relationships and data-driven selection of source datasets. *The Computer Journal*, p. bxs092, 2012. Citado na página 34.

GIRSCHICK, T.; RUCKERT, U.; KRAMER, S. Adapted transfer of distance measures for quantitative structure-activity relationships and data-driven selection of source datasets. *The Computer Journal*, v. 53, n. 6, p. 274–288, 2013. Citado na página 36.

GLEESON, M.; MODI, S.; BENDER, A.; ROBINSON, R. M.; KIRCHMAIR, J.; PROMKATKAEW, M.; HANNONGBUA, S.; GLEN, R. The challenges involved in modeling toxicity data in silico: A review. *Current pharmaceutical design*, v. 18, p. 1266–1291, 2012. Citado na página 26.

GRIFFEN, E.; DOSSETTER, A.; LEACH, A.; MONTAGUE, S. Can we accelerate medicinal chemistry by augmenting the chemist with big data and artificial intelligence? *Drug discovery today*, v. 23, n. 7, p. 1373–1384, 2018. Citado na página 37.

GRUBER, T. Toward principles for the design of ontologies used for knowledge sharing? *International Journal of Human-Computer Studies*, v. 43, p. 907–928, 1995. Citado na página 18.

GUARINO, N.; OBERLE, D.; STAAB, S. What is an ontology? In: STAAB, S.; STUDER, R. (Ed.). *Handbook on Ontologies*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2009. p. 1–17. Citado na página 18.

GUERSON, J.; SALES, T. P.; GUIZZARDI, G.; ALMEIDA, J. P. A. OntoUML lightweight editor: A model-based environment to build, evaluate and implement reference ontologies. In: *Proceedings of IEEE 19th International Enterprise Distributed Object Computing Workshop*. [S.l.: s.n.], 2015. p. 144–147. Citado na página 39.

GUHA, R. The ups and downs of structure-activity landscapes. In: BAJORATH, J. (Ed.). *Chemoinformatics and Computational Chemical Biology*. [S.l.: s.n.], 2011. v. 672, p. 101–117. Citado na página 22.

HAYKIN, S. S. *Neural networks and learning machines, 3rd edition*. Upper Saddle River, NJ: Pearson Education, 2009. Citado na página 30.

HILÁRIO, M. O. E.; TERRERI, M. T. R. A.; LEN, C. A. Antiinflamatórios não-hormonais: inibidores da ciclooxygenase 2. *Jornal de Pediatria*, Sociedade Brasileira de Pediatria, 2006. Citado na página 34.

HOSHI, K.; KAWAKAMI, J.; KUMAGAI, M.; KASAHARA, S.; NISHIMURA, N.; NAKAMURA, H.; SATO, K. An analysis of thyroid function diagnosis using bayesian-type and SOM-type neural networks. *Chemical pharmaceutical bulletin*, v. 53, p. 1570–1574, 2006. Citado na página 26.

JENSEN, T.; BARON, R.; HAANPÄÄ, M.; KALSO, E.; LOESER, J.; RICE, A.; TREEDE, R. A new definition of neuropathic pain. *PAIN®*, v. 152, p. 2204–2205, 2011. Citado na página 30.

JIANG, S.; HAGELIEN, T. F.; NATVIG, M.; LI, J. Ontology-based semantic search for open government data. *2019 IEEE 13th International Conference on Semantic Computing (ICSC)*, IEEE, v. 13, n. 1, p. 7–15, 2019. Citado na página 44.

JIN, G.; WONG, S. T. Toward better drug repositioning: prioritizing and integrating existing methods into efficient pipelines. *Drug Discovery Today*, v. 19, n. 5, p. 637–644, 2014. Citado na página 11.

JORDAN, M.; WILSON, L. Microtubules as a target for anticancer drugs. *Nature Reviews Cancer*, v. 4, p. 253–265, 2004. Citado na página 31.

KAUSELMANN, G.; DOPAZO, A.; LINK, W. Identification of disease-relevant genes for molecularly-targeted drug discovery. *Current cancer drug targets*, v. 12, p. 1–13, 2011. Citado na página 20.

KIM, H.; KIM, E.; LEE, I.; BAE, B.; PARK, M.; NAM, H. Artificial intelligence in drug discovery: A comprehensive review of data-driven and machine learning approaches. *Biotechnol and Bioprocess Engineering*, v. 25, p. 895–930, 2020. Citado na página 25.

KIM, S.; CHEN, J.; CHENG, T.; GINDULYTE, A.; HE, J.; HE, S.; LI, Q.; SHOEMAKER, B. A.; THIESSEN, P. A.; YU, B.; ZASLAVSKY, L.; ZHANG, J.; BOLTON, E. E. Pubchem 2019 update: improved access to chemical data. *Nucleic Acids Research*, v. 47, n. D1, p. 102–109, 2019. Citado 3 vezes nas páginas 21, 36 e 42.

KONG, W.; TU, X.; HUANG, W.; YANG, Y.; XIE, Z.; HUANG, Z. Prediction and optimization of nav1.7 sodium channel inhibitors based on machine learning and simulated annealing. *Journal of Chemical Information and Modeling*, v. 60, n. 6, p. 2739–2753, 2020. Citado na página 25.

LACHANCE, H.; WETZEL, S.; KUMAR, K.; WALDMANN, H. Charting, navigating, and populating natural product chemical space for drug discovery. *Journal of medicinal chemistry*, v. 55, p. 5989–6001, 2012. Citado na página 20.

LAI, P.; PHAN, N.; HU, H.; BADETI, A.; NEWMAN, D.; DOU, D. Ontology-based interpretable machine learning for textual data. In: *2020 International Joint Conference on Neural Networks (IJCNN)*. [S.l.: s.n.], 2020. p. 1–10. Citado na página 24.

LEAL, G. S. S.; GUÉDRIA, W.; PANETTO, H. An ontology for interoperability assessment: A systemic approach. *Journal of Industrial Information Integration*, v. 16, p. 100100, 2019. Citado na página 18.

LIMA, C. A. d. M. *Comitê de Máquinas: uma abordagem unificada empregando máquinas de vetores-suporte*. Tese (Doutorado) — Universidade Estadual de Campinas, 2004. Citado 2 vezes nas páginas 5 e 16.

LIPINSKI, C.; OLIVEIRA, A.; HONÓRIO, K.; OLIVEIRA, P.; SILVA, A. A molecular modeling study of combretastatin-like chalcones as anticancer agents using PLS, ANN and consensus models. *Structural Chemistry*, v. 29, 2018. Citado na página 31.

- LIPINSKI, C. F.; MALTAROLLO, V. G.; OLIVEIRA, P. R.; SILVA, A.; HONÓRIO, K. M. Advances and perspectives in applying deep learning for drug design and discovery. *Frontiers in Robotics and AI*, v. 6, p. 108, 2019. Citado na página 28.
- MADHUKAR, N.; KHADE, P.; HUANG, L.; GAYVERT, K.; GALLETTI, G.; STOGNIEW, M.; ALLEN, J.; GIANNAKAKOU, P.; ELEMENTO, O. A bayesian machine learning approach for drug target identification using diverse data types. *Nature Communications*, v. 10, 11 2019. Citado na página 25.
- MALTAROLLO, V.; KRONENBERGER, T.; ESPINOZA, G.; OLIVEIRA, P.; HONÓRIO, K. Advances with support vector machines for novel drug discovery. *Expert Opinion on Drug Discovery*, v. 14, p. 1–11, 2018. Citado na página 28.
- MALTAROLLO, V. G.; GERTRUDES, J. C.; OLIVEIRA, P. R.; HONORIO, K. M. Applying machine learning techniques for ADME-Tox prediction: a review. *Expert Opinion on Drug Metabolism & Toxicology*, v. 11, n. 2, p. 259–271, 2015. Citado 2 vezes nas páginas 25 e 26.
- MALTAROLLO, V. G.; HONORIO, K. M. Ligand-and structure-based drug design strategies and ppar δ / α selectivity. *Chemical biology & drug design*, Wiley Online Library, v. 80, n. 4, p. 533–544, 2012. Citado na página 34.
- MAURICE, T.; SU, T.-P. The pharmacology of sigma-1 receptors. *Pharmacology therapeutics*, v. 124, p. 195–206, 2009. Citado na página 30.
- MAZIARKA, ; POCHA, A.; KACZMARCZYK, J.; RATAJ, K.; DANIEL, T.; WARCHOŁ, M. Mol-CycleGAN: A generative model for molecular optimization. *Journal of Cheminformatics*, v. 12, 2020. Citado na página 25.
- MCINNES, B. T.; PEDERSEN, T. Evaluating semantic similarity and relatedness over the semantic grouping of clinical term pairs. *Journal of Biomedical Informatics*, ELSEVIER, v. 1, n. 54, p. 329–336, 2015. Citado 2 vezes nas páginas 44 e 45.
- MENDES, C. C.; BISELLI, J. M.; ZAMPIERI, B. L.; GOLONI-BERTOLLO, E. M.; EBERLIN, M. N.; HADDAD, R.; RICCIO, M. F.; VANNUCCHI, H.; CARVALHO, V. M.; PAVARINO-BERTELLI, É. C. 19-base pair deletion polymorphism of the dihydrofolate reductase (dhfr) gene: maternal risk of down syndrome and folate metabolism. *Sao Paulo Medical Journal*, SciELO Brasil, v. 128, n. 4, p. 215–218, 2010. Citado na página 34.
- MICHIELAN, L.; MORO, S. Pharmaceutical perspectives of nonlinear qsar strategies. *Journal of chemical information and modeling*, ACS Publications, v. 50, n. 6, p. 961–978, 2010. Citado na página 23.
- MILAC, A.; AVRAM, S.; PETRESCU, A. Evaluation of a neural networks qsar method based on ligand representation using substituent descriptors. application to HIV-1 protease inhibitors. *Journal of molecular graphics & modelling*, v. 25 1, p. 37–45, 2006. Citado na página 26.
- MONTANARI, C. A. *Química medicinal: métodos e fundamentos em planejamento de fármacos*. [S.l.: s.n.], 2011. Citado na página 21.
- MORIWAKI, H.; TIAN, Y.; KAWASHITA, N.; TAKAGI, T. Mordred: A molecular descriptor calculator. *Journal of Cheminformatics*, v. 10, 2018. Citado 2 vezes nas páginas 21 e 42.

- MYERS, J.; WELL, A.; LORCH, R. *Research Design and Statistical Analysis*. [S.l.: s.n.], 2013. Citado na página [45](#).
- NIELSEN, T.; SCHREIBER, S. Towards the optimal screening collection: A synthesis strategy. *Angewandte Chemie (International ed. in English)*, v. 47, p. 48–56, 2008. Citado na página [20](#).
- NIGHTINGALE, S. The neuropathic pain market. *Nature reviews on Drug discovery*, v. 11, p. 101–2, 2012. Citado na página [30](#).
- O'BOYLE, N. M. Towards a universal smiles representation - a standard method to generate canonical smiles based on the inchi. *Journal of Cheminformatics*, v. 4, n. 22, 2012. Citado na página [42](#).
- O'BOYLE, N. M.; BANCK, M.; JAMES, C. A.; MORLEY, C.; VANDERMEERSCH, T.; HUTCHISON, G. R. Open babel: An open chemical toolbox. *Journal of Cheminformatics*, v. 3, n. 33, 2011. Citado na página [42](#).
- OLIVEIRA, A. A.; LIPINSKI, C. F.; PEREIRA, E. B.; HONORIO, K. M.; OLIVEIRA, P. R.; WEBER, K. C. AND ROMERO, R.; SOUSA, A. G. de; SILVA, A. da. New consensus multivariate models based on pls and ann studies of sigma-1 receptor antagonists. *Journal of molecular modeling*, v. 23, n. 10, 2017. Citado na página [30](#).
- PAN, S. J.; YANG, Q. A survey on transfer learning. *IEEE TRANSACTIONS ON KNOWLEDGE AND DATA ENGINEERING*, IEEE Computer Society, v. 22, n. 10, p. 1345–1359, 2010. Citado na página [34](#).
- PIRES, D. E. V.; BLUNDELL, T. L.; ASCHER, D. B. pkCSM: Predicting small-molecule pharmacokinetic and toxicity properties using graph-based signatures. *Journal of Medicinal Chemistry*, v. 58, n. 9, p. 4066–4072, 2015. Citado na página [43](#).
- RIBEIRO, M. T.; SINGH, S.; GUESTIN, C. “why should i trust you?”: Explaining the predictions of any classifier. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. [S.l.: s.n.], 2016. (KDD '16), p. 1135–1144. Citado na página [46](#).
- ROSENBAUM, L.; DÖRR, A.; BAUER, M. R.; BOECKLER, F. M.; ZELL, A. Inferring multi-target qsar models with taxonomy-based multi-task learning. *J. Cheminformatics*, Journal of Cheminformatics, v. 5, n. 1-2, p. 33, 2013. Citado 3 vezes nas páginas [5](#), [32](#) e [33](#).
- RUMELHART, D.; HILTON, G. E.; WILLIAMS, R. J. Learning internal representations by error propagation. In: *Parallel Distributed Processing, Volume 1: Foundations*. Cambridge: MIT Press, 1986. Citado na página [30](#).
- RÉDA, C.; KAUFMANN, E.; DELAHAYE-DURIEZ, A. Machine learning applications in drug development. *Computational and Structural Biotechnology Journal*, v. 18, p. 241–252, 2020. Citado 3 vezes nas páginas [5](#), [12](#) e [25](#).
- SCHENONE, M.; DANČÍK, V.; WAGNER, B.; CLEMONS, P. Target identification and mechanism of action in chemical biology and drug discovery. *Nature chemical biology*, v. 9, p. 232–240, 2013. Citado na página [21](#).

- SCHNEIDER, P.; TANRIKULU, Y.; SCHNEIDER, G. Self-organizing maps in drug discovery: Compound library design, scaffold-hopping, repurposing. *Current medicinal chemistry*, v. 16, p. 258–66, 2009. Citado na página 26.
- SERAFIM, M.; GERTRUDES, J. C.; COSTA, D.; OLIVEIRA, P.; MALTAROLLO, V.; HONÓRIO, K. Knowing and combating the enemy: a brief review on SARS-CoV-2 and computational approaches applied to the discovery of drug candidates. *Bioscience Reports*, v. 41, 2021. Citado na página 29.
- SERAFIM, M.; KRONENBERGER, T.; OLIVEIRA, P.; POSO, A.; HONÓRIO, K.; MOTA, B.; MALTAROLLO, V. The application of machine learning techniques to innovative antibacterial discovery and development. *Expert Opinion on Drug Discovery*, v. 15, p. 1–15, 2020. Citado na página 29.
- SESSIONS, Z.; CRUZ, N. S.; PRIETO-MARTÍNEZ, F.; ALVES, V.; JR, H. S.; MURATOV, E.; TROPSHA, A.; MEDINA-FRANCO, J. Recent progress on cheminformatics approaches to epigenetic drug discovery. *Drug discovery today*, v. 25, p. 2268–2276, 2020. Citado na página 37.
- SHARMA, R.; KUMAR, R.; KODWANI, R.; KAPOOR, S.; KHARE, A.; BANSAL, R.; KHURANA, S.; SINGH, S.; THOMAS, J.; ROY, B.; PHARTYAL, R.; SALUJA, S.; KUMAR, S. A review on mechanisms of anti tumor activity of chalcones. *Anti-cancer agents in medicinal chemistry*, v. 15, 2015. Citado na página 31.
- SIMÕES, R. S.; OLIVEIRA, P. R.; HONÓRIO, K. M.; LIMA, C. A. M. Applying transfer learning to QSAR regression models. In: LATIFI, S. (Ed.). *Information Technology - New Generations*. Las Vegas, USA: Springer International Publishing, 2018. p. 631–637. Citado 3 vezes nas páginas 32, 34 e 46.
- SIMÕES, R.; MALTAROLLO, V.; OLIVEIRA, P.; HONÓRIO, K. Transfer and multi-task learning in qsar modeling: Advances and challenges. *Frontiers in Pharmacology*, v. 9, 2018. Citado na página 28.
- SIMÕES, R. S. *Técnicas de transferência de aprendizagem aplicadas a modelos QSAR para regressão*. Dissertação (Mestrado) — Universidade de São Paulo, 2018. Citado na página 33.
- SMOLA, A. J. Regression estimation with support vector learning machines. *Master's thesis, Technische Universit at München*, 1996. Citado na página 15.
- SOUZA, J. C. S. de; CLAUDINO, S. G.; SIMOES, R. da S.; OLIVEIRA, P. R.; HONORIO, K. M. Recent advances for handling imbalance and uncertainty in labelling in medicinal chemistry data analysis. In: *2016 SAI Computing Conference (SAI)*. London, UK: [s.n.], 2016. p. 217–222. Citado na página 27.
- SPOLADORE, D.; PESSOT, E. Collaborative ontology engineering methodologies for the development of decision support systems: Case studies in the healthcare domain. *Electronics*, v. 10, n. 9, 2021. Citado na página 18.
- STOJIC, N.; ERIĆ, S.; KUZMANOVSKI, I. Prediction of toxicity and data exploratory analysis of estrogen-active endocrine disruptors using counter-propagation artificial neural networks. *Journal of Molecular Graphics and Modelling*, v. 29, n. 3, p. 450–460, 2010. Citado na página 26.

- SUTHERLAND, J. J.; O'BRIEN, L. A.; WEAVER, D. F. Spline-fitting with a genetic algorithm: A method for developing classification structure-activity relationships. *Journal of chemical information and computer sciences*, ACS Publications, v. 43, n. 6, p. 1906–1915, 2003. Citado na página 34.
- TAN, B.; SONG, Y.; ZHONG, E.; YANG, Q. Transitive transfer learning. In: *Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. [S.l.: s.n.], 2015. p. 1155–1164. Citado na página 36.
- VAPNIK, V. *The Nature of Statistical Learning Theory*. [S.l.]: Springer New York, 1999. (Information Science and Statistics). Citado 2 vezes nas páginas 15 e 28.
- VARNEK, A.; BASKIN, I. Machine learning methods for property prediction in chemoinformatics: Quo Vadis? *Journal of chemical information and modeling*, v. 52, n. 6, p. 1413–1437, 2012. Citado na página 27.
- VATANSEVER, S.; SCHLESSINGER, A.; WACKER, D.; KANISKAN, H. ; JIN, J.; ZHOU, M.-M.; ZHANG, B. Artificial intelligence and machine learning-aided drug discovery in central nervous system diseases: State-of-the-arts and future directions. *Medicinal Research Reviews*, v. 41, n. 3, p. 1427–1473, 2021. Citado na página 25.
- WANG, S.; LI, Z. A new transfer learning boosting approach based on distribution measure with an application on facial expression recognition. In: *Proceedings of 2014 IEEE International Joint Conference on Neural Networks*. [S.l.: s.n.], 2014. (IJCNN '14), p. 432–439. Citado 2 vezes nas páginas 32 e 36.
- WANG, T.; WU, M.-B.; LIN, J.-P.; YANG, L.-R. Quantitative structure–activity relationship: promising advances in drug discovery platforms. *Expert Opinion on Drug Discovery*, v. 10, n. 12, p. 1283–1300, 2015. Citado na página 25.
- WERMUTH, C.; GANELLIN, C.; LINDBERG, P. Glossary of terms used in medicinal chemistry (IUPAC recommendations 1998). *Pure and applied chemistry*, v. 70, n. 5, p. 1129–1143, 1998. Citado na página 22.
- WOLD, H. Partial least squares. In: *Encyclopedia of Statistical Science*. [S.l.: s.n.], 2004. Citado na página 30.
- YAP, C. W. Padel-descriptor: An open source software to calculate molecular descriptors and fingerprints. *Journal of computational chemistry*, v. 32, p. 1466–74, 2011. Citado 2 vezes nas páginas 21 e 42.
- YOUNG, D. C. *Computational Drug Design - A Guide for Computational and Medicinal Chemists*. [S.l.]: John Wiley & Sons, Inc., 2009. Citado 2 vezes nas páginas 10 e 21.
- ZAKHAROV, A.; PEACH, M.; SITZMANN, M.; NICKLAUS, M. QSAR modeling of imbalanced high-throughput screening data in PubChem. *Journal of Chemical Information and Modeling*, v. 54, p. 705 – 712, 2014. Citado na página 27.
- ZHANG, W.; XIONG, Y.; ZHAO, M.; ZOU, H.; YE, X.; LIU, J. Prediction of conformational B-cell epitopes from 3D structures by random forests with a distance-based feature. *BMC Bioinformatics*, v. 12, p. 341 – 341, 2011. Citado na página 27.

ZHAO, L.; WANG, W.; SEDYKH, A.; ZHU, H. Experimental errors in qsar modeling sets: What we can do and what we cannot do. *ACS Omega*, v. 2, p. 2805–2812, 2017. Citado na página [32](#).

ZHENG, K.; YOU, Z.-H.; WANG, L.; YONG, Z.; LI, L.-P.; LI, Z.-W. MLMDA: a machine learning approach to predict and validate microrna–disease associations by integrating of heterogenous information sources. *Journal of Translational Medicine*, v. 17, 2019. Citado na página [25](#).